



ESTATÍSTICA PARA ENGENHARIA

HOMEWORK 01

ANÁLISE DE COMPARTILHAMENTO DE BICICLETAS: UMA ABORDAGEM EM ESTATÍSTICA DESCRITIVA

ALUNOS:

ALEXANDRE DE AGUIAR MARTINS GRANGEIRO – 578345

BRUNO DELUIZ LAGE – 578342

DANNY SECUNDINO SOUSA FILHO – 579763

SAULO GOMES PINTO – 579493

1 Questão 1

A primeira questão tem o objetivo de definir o escopo de dados a serem utilizados pelo grupo ao longo de toda a análise. Para isso, foi feito um código R que fazia o que foi pedido no enunciado da questão. O código é este:

```
# =====  
# First Question  
# =====  
  
# 1. Defining the highest student number  
# students numbers  
alexandre_sn <- 578345  
bruno_sn <- 578342  
danny_sn <- 579763  
saulo_sn <- 579493  
  
# highest student number  
M <- max(c(alexandre_sn, bruno_sn, danny_sn, saulo_sn)) # 579763  
  
# 2. Defining the start and the end of group's dataset  
# start  
r <- 1 + (M %% 100)      # 64  
  
# end  
end <- 300 + r - 1      # 363  
  
# 3. Defining data_group (ie., the group's dataset)  
# loading the entire file  
all_data <- read.csv("HW1_bike_sharing.csv")  
  
# defining our scope  
data_group <- all_data[r:end, ]      # collect the lines 64-363  
  
# 4. Defining the first 10 observations (we'll use them in the subsequent questions to  
#     validate our manual computations)  
first_ten <- data_group[1:10, ]
```

É importante analisar o que, de fato, foi implementado com esse código:

Primeiramente, foram definidas variáveis *_sn contendo, cada uma, o valor do número de matrícula de um dos quatro integrantes do grupo. Os valores dos números de matrículas são os seguintes:

- a) Alexandre Grangeiro: 578345;
- b) Bruno Lage: 578342;
- c) Danny Secundino: 579763;
- d) Saulo Gomes: 579493.

Após isso, a variável M foi declarada para guardar o maior número de matrícula dentre os números de matrícula dos membros do grupo. Dessa forma, obtém-se

$$M = 579763$$

Com a informação do maior número de matrícula, foi possível, então, definir o índice inicial do subconjunto de dados a ser analisado nesse trabalho. Tal informação ficou guardada na variável r e ele

foi calculado da seguinte maneira:

$$r = 1 + (M \bmod 100) = 1 + (579763 \bmod 100) = 1 + 63 \Rightarrow \boxed{r = 64}$$

Em que *mod* é a operação **resto de divisão**.¹

Com o índice de início do conjunto de dados a ser analisado e considerando que tal conjunto deveria ter 300 elementos, também foi definido o fim:

$$end = 300 + r - 1 = 300 + 64 - 1 \Rightarrow end = 363$$

Com o início e o fim da janela que define o escopo das análises, foi declarado o `data_group`, que pode ser usado ao longo de todo o código para fazer as outras questões. Também foi definido o `first_ten`, que contém as dez primeiras observações do conjunto de dados do grupo e que será especialmente útil para comparar os cálculos que serão feitos manualmente com os que serão obtidos com o código R.

Daí, foi possível coletar as datas da primeira e da última observação presentes em `data_group`. Elas foram:

- a) Data da primeira observação: 05/03/2011 (ou, no formato internacional, 2011-03-05)
- b) Data da última observação: 29/12/2011 (ou, no formato internacional, 2011-12-29)

Além disso, vale também apresentar as dez primeiras observações para que a análise ao longo do relatório seja melhor referenciada. Elas estão dispostas na tabela a seguir:

Tabela 1: Primeiras dez observações do conjunto `data_group`

Instant	Data	Estação	Clima	Temp.	Casual	Registrados	Total	Baixa Utiliz.
64	2011-03-05	1	2	15.8	640	1437	2077	0
65	2011-03-06	1	2	15.4	114	491	605	1
66	2011-03-07	1	1	10.7	244	1628	1872	1
67	2011-03-08	1	1	12.0	316	1817	2133	0
68	2011-03-09	1	2	12.1	191	1700	1891	0
69	2011-03-10	1	3	16.0	46	577	623	1
70	2011-03-11	1	2	13.0	247	1730	1977	0
71	2011-03-12	1	1	13.5	724	1408	2132	0
72	2011-03-13	1	1	15.8	982	1435	2417	0
73	2011-03-14	1	1	13.3	359	1687	2046	0

As variáveis `total_user` e `low_usage` também foram incluídas na tabela, de modo a consolidar em uma única tabela todos os dados que serão utilizados ao longo das análises seguintes.

Observação: Aqui, foram postas as datas da primeira e da última observações, mas essa informação também consta na saída do código fonte produzido. **Recomenda-se que se execute o código `main.r` para ver as informações que são fornecidas na saída.**

2 Questão 2

Jovem, temos que responder aos seguinte enunciados e, em cada caso que pedir algum cálculo, fazê-lo à mão com as 10 primeiras observações (eu coloquei em uma tabela na questão anterior, pode

¹Em R, essa operação é realizada utilizando `%%`.

conferir) do nosso dataset para comparar com o que deu o código R. Depois analise o que foi apresentado. para você pegar os dados que o código R fornece, não precisa, a priori, entrar no código: eu fiz uma interface no terminal para ajudar a gnt a só pegar os dados que nos inteia. pressam do código! Para rodar o código, navegue até a pasta em que está o código e rode: `Rscript main.r!`

2.1 Ponto 1

1. Realize as seguintes análises [Perform the following analyses]: * Classifique cada variável quanto ao seu tipo (categórica ou numérica) e justifique a classificação [Classify each variable according to its type (categorical or numerical) and justify the classification]. * Identifique as categorias das variáveis categóricas [Identify the categories of the categorical variables]. * Para cada variável numérica, identifique a unidade de medida, quando aplicável, e descreva o que ela representa [For each numerical variable, identify its unit of measurement, where applicable, and describe what it represents]. * Verifique a existência de valores ausentes e, caso existam, quantifique-os e indique em quais variáveis ocorrem [Check for missing values and, if any are found, quantify them and indicate which variables contain them].

2.2 Ponto 2

Para as variáveis numéricas relevantes, calcule as medidas de tendência central: média, mediana e, quando aplicável, moda. Explique o significado de cada medida e interprete os resultados obtidos no contexto do conjunto de dados

2.3 Ponto 3

Escolha uma das variáveis numéricas relevantes e determine os quartis Q1 , Q2 e Q3 e o intervalo interquartil. Justifique a escolha da variável e utilize o critério do intervalo interquartil para determinar os limites inferior e superior para a identificação de possíveis valores atípicos. Quantifique as observações classificadas como possíveis valores atípicos e identifique suas respectivas datas. Discuta a relevância dos valores identificados para a análise do sistema

2.4 Ponto 4

Para a variável numérica escolhida no item anterior, construa um histograma e um boxplot. Analise a distribuição quanto à sua forma, dispersão, assimetria e presença de possíveis valores atípicos. Relacione as características observadas nos gráficos com as medidas estatísticas calculadas anteriormente e discuta quais aspectos da distribuição são melhor evidenciados por cada tipo de gráfico

2.5 Ponto 5

Com base nos quartis calculados anteriormente, utilize o primeiro quartil Q1 como critério para classificar um dia como de “baixa utilização” do sistema. A partir desse critério, crie a variável binária `low_usage`, definida pela Equação

[já foi definido], abra o código.

Apresente o valor de Q1 , determine o número e a proporção de dias classificados como de baixa utilização e explique o significado desse critério no contexto dos dados

3 Questão 3

4 Questão 4