



ESTATÍSTICA PARA ENGENHARIA

HOMEWORK 01

ANÁLISE DE COMPARTILHAMENTO DE BICICLETAS: UMA ABORDAGEM EM ESTATÍSTICA DESCRITIVA

ALUNOS:

ALEXANDRE DE AGUIAR MARTINS GRANGEIRO – 578345

BRUNO DELUIZ LAGE – 578342

DANNY SECUNDINO SOUSA FILHO – 579763

SAULO GOMES PINTO – 579493

1 Questão 1

A primeira questão tem o objetivo de definir o escopo de dados a serem utilizados pelo grupo ao longo de toda a análise. Para isso, foi feito um código R que fazia o que foi pedido no enunciado da questão. O código é este:

```
# =====  
# First Question  
# =====  
  
# 1. Defining the highest student number  
# students numbers  
alexandre_sn <- 578345  
bruno_sn <- 578342  
danny_sn <- 579763  
saulo_sn <- 579493  
  
# highest student number  
M <- max(c(alexandre_sn, bruno_sn, danny_sn, saulo_sn)) # 579763  
  
# 2. Defining the start and the end of group's dataset  
# start  
r <- 1 + (M %% 100)      # 64  
  
# end  
end <- 300 + r - 1      # 363  
  
# 3. Defining data_group (ie., the group's dataset)  
# loading the entire file  
all_data <- read.csv("HW1_bike_sharing.csv")  
  
# defining our scope  
data_group <- all_data[r:end, ]      # collect the lines 64-363  
  
# 4. Defining the first 10 observations (we'll use them in the subsequent questions to  
# validate our manual computations)  
first_ten <- data_group[1:10, ]
```

É importante analisar o que, de fato, foi implementado com esse código:

Primeiramente, foram definidas variáveis *_sn contendo, cada uma, o valor do número de matrícula de um dos quatro integrantes do grupo. Os valores dos números de matrículas são os seguintes:

- a) Alexandre Grangeiro: 578345;
- b) Bruno Lage: 578342;
- c) Danny Secundino: 579763;
- d) Saulo Gomes: 579493.

Após isso, a variável M foi declarada para guardar o maior número de matrícula dentre os números de matrícula dos membros do grupo. Dessa forma, obtém-se

$$M = 579763$$

Com a informação do maior número de matrícula, foi possível, então, definir o índice inicial do subconjunto de dados a ser analisado nesse trabalho. Tal informação ficou guardada na variável r e ele

foi calculado da seguinte maneira:

$$r = 1 + (M \bmod 100) = 1 + (579763 \bmod 100) = 1 + 63 \Rightarrow \boxed{r = 64}$$

Em que *mod* é a operação **resto de divisão**.¹

Com o índice de início do conjunto de dados a ser analisado e considerando que tal conjunto deveria ter 300 elementos, também foi definido o fim:

$$end = 300 + r - 1 = 300 + 64 - 1 \Rightarrow end = 363$$

Com o início e o fim da janela que define o escopo das análises, foi declarado o `data_group`, que pode ser usado ao longo de todo o código para fazer as outras questões. Também foi definido o `first_ten`, que contém as dez primeiras observações do conjunto de dados do grupo e que será especialmente útil para comparar os cálculos que serão feitos manualmente com os que serão obtidos com o código R.

Daí, foi possível coletar as datas da primeira e da última observação presentes em `data_group`. Elas foram:

- a) Data da primeira observação: 05/03/2011 (ou, no formato internacional, 2011-03-05)
- b) Data da última observação: 29/12/2011 (ou, no formato internacional, 2011-12-29)

Além disso, vale também apresentar as dez primeiras observações para que a análise ao longo do relatório seja melhor referenciada. Elas estão dispostas na tabela a seguir:

Tabela 1: Primeiras dez observações do conjunto `data_group`

Instant	Data	Estação	Clima	Temp.	Casual	Registrados	Total	Baixa Utiliz.
64	2011-03-05	1	2	15.8	640	1437	2077	0
65	2011-03-06	1	2	15.4	114	491	605	1
66	2011-03-07	1	1	10.7	244	1628	1872	1
67	2011-03-08	1	1	12.0	316	1817	2133	0
68	2011-03-09	1	2	12.1	191	1700	1891	0
69	2011-03-10	1	3	16.0	46	577	623	1
70	2011-03-11	1	2	13.0	247	1730	1977	0
71	2011-03-12	1	1	13.5	724	1408	2132	0
72	2011-03-13	1	1	15.8	982	1435	2417	0
73	2011-03-14	1	1	13.3	359	1687	2046	0

As variáveis `total_user` e `low_usage` também foram incluídas na tabela, de modo a consolidar em uma única tabela todos os dados que serão utilizados ao longo das análises seguintes.

Observação: Aqui, foram postas as datas da primeira e da última observações, mas essa informação também consta na saída do código fonte produzido. **Recomenda-se que se execute o código `main.r` para ver as informações que são fornecidas na saída.**

¹Em R, essa operação é realizada utilizando `%%`.

2 Questão 2

O objetivo desta seção é caracterizar o conjunto de dados específico do grupo (`data_group`), definido na Questão 1, calcular e interpretar as medidas de tendência central e os quartis das variáveis numéricas relevantes, identificar possíveis valores atípicos e definir a variável `low_usage`. As análises foram realizadas inicialmente de forma manual, com as dez primeiras observações do conjunto (`first_ten`), e, em seguida, verificadas e estendidas às 300 observações do grupo por meio do software R.

2.1 Ponto 1 – Caracterização das Variáveis

2.1.1 Classificação das variáveis

- `instant` – Numérica (discreta): índice sequencial que identifica cada registro; assume valores inteiros que apenas ordenam as observações, sem magnitude física associada.
- `dtoday` – Categórica (ordinal): representa a data da observação; ainda que expressa em formato numérico (ano-mês-dia), não é submetida a operações aritméticas, apenas ordena os registros no tempo.
- `season` – Categórica (nominal): codifica a estação do ano por meio de rótulos numéricos sem relação de ordem ou magnitude entre si.
- `weathersit` – Categórica (ordinal): codifica a condição meteorológica; os códigos seguem uma ordem crescente de severidade do tempo.
- `temp` – Numérica (contínua): representa a temperatura do dia, em graus Celsius; assume valores reais dentro de um intervalo contínuo.
- `casual` – Numérica (discreta): representa a contagem diária de usuários casuais; assume apenas valores inteiros não negativos.
- `registered` – Numérica (discreta): representa a contagem diária de usuários registrados; assume apenas valores inteiros não negativos.
- `total_user` – Numérica (discreta): variável derivada (`casual + registered`); representa o total diário de usuários do sistema.

2.1.2 Categorias das variáveis categóricas

- `season`: 1 – inverno, 2 – primavera, 3 – verão, 4 – outono (estações do ano no hemisfério norte).
- `weathersit`: 1 – céu limpo, 2 – nublado, 3 – chuva fraca, 4 – chuva forte (ordenadas por severidade da condição meteorológica).

Cabe observar que, no subconjunto de 300 observações do grupo (`data_group`), não há nenhum dia classificado com `weathersit = 4` (chuva forte), de modo que essa categoria, embora definida, não é representada na amostra analisada.

2.1.3 Unidades e significado das variáveis numéricas

- `instant`: sem unidade de medida; identificador sequencial do registro.
- `temp`: graus Celsius; representa a temperatura observada no dia.

- `casual`: pessoas/dia; representa a quantidade de usuários que utilizaram o sistema sem vínculo de cadastro.
- `registered`: pessoas/dia; representa a quantidade de usuários cadastrados que utilizaram o sistema no mesmo dia.
- `total_user`: pessoas/dia; variável derivada que soma `casual` e `registered`, representando o total de usuários do sistema em cada dia observado.

2.1.4 Valores ausentes

A verificação de valores ausentes foi feita por meio da função `is.na()` aplicada a `data_group` (variável `has_missing_values` no código). O resultado obtido foi `FALSE`, isto é, não há valores ausentes em nenhuma das variáveis do conjunto de 300 observações do grupo.

2.2 Ponto 2 – Medidas de Tendência Central

As medidas de tendência central foram calculadas para as variáveis numéricas relevantes (`temp`, `casual`, `registered` e `total_user`): média, mediana e, quando aplicável, moda.

A média aritmética $\bar{x}$ é dada por

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

A mediana Me corresponde ao valor central do conjunto ordenado (ou à média dos dois valores centrais, quando n é par):

$$Me = \frac{x_{(n/2)} + x_{(n/2+1)}}{2}, \quad \text{para } n \text{ par}$$

Para o cálculo manual, considera-se

$$n = 10$$

2.2.1 Cálculo manual – 10 primeiras observações

A Tabela 2 apresenta os valores de cada variável ordenados de forma crescente, com os dois valores centrais (posições 5 e 6, usados no cálculo da mediana) destacados em negrito.

Tabela 2: Valores ordenados (crescente) – 10 primeiras observações

Posição	temp (°C)	casual	registered	total_user
1	10,7	46	491	605
2	12,0	114	577	623
3	12,1	191	1408	1872
4	13,0	244	1435	1891
5	13,3	247	1437	1977
6	13,5	316	1628	2046
7	15,4	359	1687	2077
8	15,8	640	1700	2132
9	15,8	724	1730	2133
10	16,0	982	1817	2417

temp

$$\begin{aligned}\bar{x} &= (10,7 + 12,0 + 12,1 + 13,0 + 13,3 \\ &\quad + 13,5 + 15,4 + 15,8 + 15,8 + 16,0) / 10 \\ &= 137,6 / 10 = 13,76 \text{ }^{\circ}\text{C}\end{aligned}$$

$$Me = \frac{13,3 + 13,5}{2} = 13,40 \text{ }^{\circ}\text{C}$$

casual

$$\begin{aligned}\bar{x} &= (46 + 114 + 191 + 244 + 247 \\ &\quad + 316 + 359 + 640 + 724 + 982) / 10 \\ &= 3863 / 10 = 386,30\end{aligned}$$

$$Me = \frac{247 + 316}{2} = 281,50$$

registered

$$\begin{aligned}\bar{x} &= (491 + 577 + 1408 + 1435 + 1437 \\ &\quad + 1628 + 1687 + 1700 + 1730 + 1817) / 10 \\ &= 13910 / 10 = 1391,00\end{aligned}$$

$$Me = \frac{1437 + 1628}{2} = 1532,50$$

total_user

$$\begin{aligned}\bar{x} &= (605 + 623 + 1872 + 1891 + 1977 \\ &\quad + 2046 + 2077 + 2132 + 2133 + 2417) / 10 \\ &= 17773 / 10 = 1777,30\end{aligned}$$

$$Me = \frac{1977 + 2046}{2} = 2011,50$$

Os valores calculados manualmente coincidem com os obtidos por meio do código R (variáveis `xn_first10_*` e `me_first10_*`), conforme resumido na Tabela 3:

Tabela 3: Medidas de tendência central – 10 primeiras observações

Variável	Média	Mediana	Moda
temp	13,76 °C	13,40 °C	–
casual	386,30	281,50	–
registered	1391,00	1532,50	–
total_user	1777,30	2011,50	–

Os mesmos cálculos foram estendidos às 300 observações do grupo (variáveis `xn_*` e `me_*`):

Para nenhuma das quatro variáveis numéricas há um valor que se repita com frequência relevante, de modo que a moda não constitui uma medida significativa nesse conjunto de dados, tanto nas 10 primeiras observações quanto nas 300 observações do grupo.

Tabela 4: Medidas de tendência central – 300 observações do grupo

Variável	Média	Mediana	Moda
temp	22,11 °C	22,20 °C	–
casual	786,92	691,50	–
registered	3025,08	3238,50	–
total_user	3812,00	4067,50	–

Nas 300 observações, observa-se que a média de `casual` (786,92) é superior à sua mediana (691,50), indicando uma distribuição assimétrica à direita: a maioria dos dias apresenta uso casual moderado, enquanto um número menor de dias com uso muito elevado eleva o valor da média. Padrão semelhante, embora menos acentuado, é observado nas 10 primeiras observações. Já para `registered` e `total_user`, a média é ligeiramente inferior à mediana, sugerindo leve assimetria à esquerda, compatível com a existência de alguns dias de uso registrado bastante baixo (possivelmente fins de semana ou feriados) que reduzem o valor médio. A variável `temp` apresenta média e mediana muito próximas nas 300 observações (22,11 °C e 22,20 °C), o que é coerente com o período coberto pela amostra do grupo, que se estende de março a dezembro de 2011, abrangendo estações de temperatura variada e resultando em uma distribuição aproximadamente simétrica.

2.3 Ponto 3 – Quartis e Valores Atípicos

A variável escolhida para a análise de quartis e valores atípicos foi `casual` (número de usuários casuais por dia). A escolha se justifica por essa variável representar o quantitativo de usuários que utilizam o sistema de forma espontânea, sem vínculo de registro (`registered`). Por não estarem associados a um cadastro fixo, esses usuários refletem de maneira mais direta a demanda ocasional pelo serviço, tornando essa variável adequada para identificar dias com comportamento de uso atípico em relação ao padrão observado.

Os quartis Q_1 , Q_2 e Q_3 dividem o conjunto ordenado de dados em quatro partes de igual tamanho. O intervalo interquartil é dado por

$$IQR = Q_3 - Q_1$$

Os limites inferior e superior para identificação de possíveis valores atípicos, segundo o critério do IQR, são dados por

$$LI = Q_1 - 1,5 \cdot IQR \quad LS = Q_3 + 1,5 \cdot IQR$$

2.3.1 Cálculo manual dos quartis – 10 primeiras observações

Para o cálculo manual, com $N = 10$, a posição de cada quartil no conjunto ordenado é obtida por

$$\text{posição}(Q_1) = \frac{N+1}{4} = \frac{11}{4} = 2,75$$

$$\text{posição}(Q_2) = \frac{N+1}{2} = \frac{11}{2} = 5,50$$

$$\text{posição}(Q_3) = \frac{3(N+1)}{4} = \frac{33}{4} = 8,25$$

Com os valores de `casual` já ordenados na Tabela 2 (46, 114, 191, 244, 247, 316, 359, 640, 724,

982), cada quartil é obtido por interpolação linear entre as posições inteiras adjacentes:

$$Q_1 = 114 + 0,75 \cdot (191 - 114) = 171,75$$

$$Q_2 = 247 + 0,5 \cdot (316 - 247) = 281,50$$

$$Q_3 = 640 + 0,25 \cdot (724 - 640) = 661,00$$

$$IQR = Q_3 - Q_1 = 661,00 - 171,75 = 489,25$$

$$LI = 171,75 - 1,5 \cdot 489,25 = -562,125 \quad LS = 661,00 + 1,5 \cdot 489,25 = 1394,875$$

Como todos os valores de `casual` nas 10 primeiras observações estão contidos no intervalo $[-562,125; 1394,875]$, nenhuma observação é classificada como atípica também pelo cálculo manual, resultado consistente com o obtido via R.

Para as 10 primeiras observações (variáveis `Q1_f10`, `Q2_f10`, `Q3_f10`, `iqr_f10`, `lower_bound_f10`, `upper_bound_f10` e `outliers_f10` no código):

Tabela 5: Quartis e limites de valores atípicos de `casual` – 10 primeiras observações

Q_1	204,25
Q_2	281,50
Q_3	569,75
IQR	365,50
Limite inferior	-344,00
Limite superior	1118,00

Observa-se que os valores de Q_1 e Q_3 calculados manualmente (171,75 e 661,00) diferem dos valores obtidos pela função `quantile()` do R (204,25 e 569,75). Essa diferença decorre da convenção de interpolação adotada por cada método: o cálculo manual utiliza a posição $\frac{N+1}{4}$ (equivalente ao tipo 6 de quantil), enquanto a função `quantile()` do R utiliza, por padrão, a posição $1 + (n - 1) \cdot p$ (tipo 7). Já a mediana ($Q_2 = 281,50$) coincide exatamente entre os dois métodos, pois ambas as convenções resultam na mesma posição central ($\frac{N+1}{2} = 5,5$) para esse caso. Em ambos os métodos, entretanto, a conclusão quanto à ausência de valores atípicos nas 10 primeiras observações se mantém.

O mesmo procedimento (via R) foi aplicado às 300 observações do grupo (variáveis `Q1`, `Q2`, `Q3`, `iqr`, `lower_bound`, `upper_bound` e `outliers`):

Tabela 6: Quartis e limites de valores atípicos de `casual` – 300 observações do grupo

Q_1	376,75
Q_2	691,50
Q_3	949,75
IQR	573,00
Limite inferior	-482,75
Limite superior	1809,25

Nas 10 primeiras observações, nenhum dia foi classificado como valor atípico: todos os valores de `casual` nesse subconjunto encontram-se dentro do intervalo $[-344,00; 1118,00]$. Já nas 300 observações do grupo, foram identificados 18 dias com valor de `casual` acima do limite superior (1809,25) – não houve valores abaixo do limite inferior, o que é esperado, já que esse limite é negativo e `casual` não assume valores negativos. As datas classificadas como atípicas estão listadas na Tabela 7.

Observa-se que todas as datas atípicas se concentram entre final de abril e meados de outubro,


Tabela 7: Dias classificados como valores atípicos de `casual` – 300 observações do grupo

Data	<code>casual</code>	Data	<code>casual</code>
30/04/2011	1965	09/07/2011	1988
21/05/2011	2258	16/07/2011	2418
28/05/2011	2001	17/07/2011	2006
29/05/2011	2355	20/08/2011	1914
04/06/2011	1869	03/09/2011	1935
26/06/2011	1920	04/09/2011	2521
02/07/2011	2204	08/10/2011	2235
03/07/2011	2282	09/10/2011	2397
04/07/2011	3065	15/10/2011	1899


período de clima mais ameno no hemisfério norte, e incluem finais de semana e datas próximas a feriados (como 04/07/2011, Dia da Independência dos EUA, e o final de semana de 28–29/05/2011, próximo ao feriado de Memorial Day). Esse padrão é coerente com a natureza da variável `casual`: por não exigir cadastro, o uso casual do sistema tende a ser mais sensível a condições favoráveis de lazer (bom tempo, folgas e feriados), o que explica a ocorrência de picos pontuais de demanda muito acima do padrão típico. Esses valores atípicos são relevantes para a análise do sistema por sinalizarem dias de pico de demanda que podem exigir redistribuição adicional de bicicletas ou reforço operacional.

2.4 Ponto 4 – Histograma e Boxplot

Para a variável `casual`, foram construídos histogramas e boxplots, tanto para as 10 primeiras observações quanto para as 300 observações do grupo, permitindo analisar forma, dispersão, assimetria e a presença de valores atípicos.


Figura 1: Distribuição de `casual` – 10 primeiras observações

Nas 10 primeiras observações, os valores de `casual` variam de 46 a 982 usuários por dia. O histograma exibe uma distribuição irregular, esperada dado o tamanho reduzido da amostra, com leve concentração nos valores mais baixos e uma cauda à direita. O boxplot correspondente não apresenta pontos além dos limites dos whiskers, em concordância com a ausência de valores atípicos apontada no Ponto 3, mas já evidencia uma mediana deslocada para a parte inferior da caixa, um primeiro indício de assimetria à direita.



(a) Histograma – 300 observações do grupo

(b) Boxplot – 300 observações do grupo

Figura 2: Distribuição de `casual` – 300 observações do grupo

Nas 300 observações do grupo, o histograma revela uma distribuição unimodal com assimetria positiva (à direita) bem mais evidente: a maior parte dos dias concentra-se na faixa entre aproximadamente 200 e 950 usuários casuais (intervalo entre Q_1 e Q_3), com uma cauda longa se estendendo até o valor máximo de 3065. O boxplot confirma esse padrão – a mediana está deslocada para a parte inferior da caixa, o whisker superior é bem mais longo que o inferior, e os 18 valores atípicos aparecem representados como pontos isolados acima do limite superior. De forma geral, o histograma evidencia melhor a forma global da distribuição (concentração, cauda e multimodalidade, caso existisse), enquanto o boxplot evidencia de forma mais direta e quantitativa os quartis, a mediana e a posição exata dos valores atípicos.

2.5 Ponto 5 – Variável `low_usage`

Com base no primeiro quartil Q_1 de `total_user`, foi definida a variável binária `low_usage`, segundo o critério

$$\text{low_usage} = \begin{cases} 1, & \text{se } \text{total_user} < Q_1 \\ 0, & \text{caso contrário} \end{cases}$$

Diferentemente da escolha de `casual` feita no Ponto 3 – em que a variável foi selecionada pelo grupo entre as opções relevantes –, aqui a variável de referência é `total_user` porque o próprio critério de definição de `low_usage`, apresentado no enunciado, utiliza explicitamente o primeiro quartil dessa variável como limiar (Equação anterior).

2.5.1 Cálculo manual de Q_1 – 10 primeiras observações

Assim como no Ponto 3, a posição do primeiro quartil no conjunto ordenado é obtida por

$$\text{posição}(Q_1) = \frac{N+1}{4} = \frac{11}{4} = 2,75, \quad N = 10$$

Com os valores de `total_user` já ordenados na Tabela 2 (605, 623, 1872, 1891, 1977, 2046, 2077,

2132, 2133, 2417), o quartil é obtido por interpolação linear entre a 2ª e a 3ª posições:

$$Q_1 = 623 + 0,75 \cdot (1872 - 623) = 1559,75$$

Esse valor difere do obtido pela função `quantile()` do R ($Q_1 = 1876,75$) pela mesma razão discutida no Ponto 3: a convenção de interpolação da posição $\frac{N+1}{4}$ (tipo 6) diverge da convenção padrão do R, $1 + (n - 1) \cdot p$ (tipo 7). Usando o valor manual (1559,75), apenas 2 das 10 primeiras observações seriam classificadas como `low_usage` (20%), contra as 3 observações (30%) obtidas com o valor verificado em R. Os resultados apresentados a seguir seguem o valor calculado via R, em consonância com a metodologia adotada no restante do relatório.

Para as 10 primeiras observações, o valor de referência foi $Q_1 = 1876,75$ (variável `Q1_lowusage_f10`), resultando em 3 dias classificados como de baixa utilização, correspondendo a uma proporção de 30% (variável `prop_lu_f10`).

Para as 300 observações do grupo, o valor de referência foi $Q_1 = 3116,50$ (variável `Q1_lowusage`), resultando em 75 dias classificados como de baixa utilização, correspondendo a uma proporção de 25% (variável `prop_lu`).

Por construção, a proporção de dias classificados como `low_usage` tende a se aproximar de 25%, já que o critério utiliza exatamente o primeiro quartil da própria distribuição de `total_user` – o que é confirmado pelo resultado obtido nas 300 observações do grupo. Na amostra reduzida de 10 observações, a proporção observada (30%) se afasta ligeiramente desse valor teórico em razão do tamanho pequeno da amostra, que torna a posição exata do quartil mais sensível a poucos valores e a possíveis empates. No contexto do sistema, os dias marcados como `low_usage` correspondem tipicamente a condições que desestimulam o uso das bicicletas – como baixas temperaturas, condições meteorológicas desfavoráveis ou dias da semana com menor mobilidade –, constituindo uma variável útil para segmentar e investigar os fatores associados à baixa demanda do sistema.

3 Questão 3

4 Questão 4