



## **ESTATÍSTICA PARA ENGENHARIA**

### **HOMEWORK 01**

#### **ANÁLISE DE COMPARTILHAMENTO DE BICICLETAS: UMA ABORDAGEM EM ESTATÍSTICA DESCRITIVA**

#### **ALUNOS:**

ALEXANDRE DE AGUIAR MARTINS GRANGEIRO – 578345

BRUNO DELUIZ LAGE – 578342

DANNY SECUNDINO SOUSA FILHO – 579763

SAULO GOMES PINTO – 579493

## 1 Questão 1

A primeira questão tem o objetivo de definir o escopo de dados a serem utilizados pelo grupo ao longo de toda a análise. Para isso, foi feito um código R que fazia o que foi pedido no enunciado da questão. O código é este:

```
# =====  
# First Question  
# =====  
  
# 1. Defining the highest student number  
# students numbers  
alexandre_sn <- 578345  
bruno_sn <- 578342  
danny_sn <- 579763  
saulo_sn <- 579493  
  
# highest student number  
M <- max(c(alexandre_sn, bruno_sn, danny_sn, saulo_sn)) # 579763  
  
# 2. Defining the start and the end of group's dataset  
# start  
r <- 1 + (M %% 100)      # 64  
  
# end  
end <- 300 + r - 1      # 363  
  
# 3. Defining data_group (ie., the group's dataset)  
# loading the entire file  
all_data <- read.csv("HW1_bike_sharing.csv")  
  
# defining our scope  
data_group <- all_data[r:end, ]      # collect the lines 64-363  
  
# 4. Defining the first 10 observations (we'll use them in the subsequent questions to  
#     validate our manual computations)  
first_ten <- data_group[1:10, ]
```

É importante analisar o que, de fato, foi implementado com esse código:

Primeiramente, foram definidas variáveis \*\_sn contendo, cada uma, o valor do número de matrícula de um dos quatro integrantes do grupo. Os valores dos números de matrículas são os seguintes:

- a) Alexandre Grangeiro: 578345;
- b) Bruno Lage: 578342;
- c) Danny Secundino: 579763;
- d) Saulo Gomes: 579493.

Após isso, a variável M foi declarada para guardar o maior número de matrícula dentre os números de matrícula dos membros do grupo. Dessa forma, obtém-se

$$M = 579763$$

Com a informação do maior número de matrícula, foi possível, então, definir o índice inicial do subconjunto de dados a ser analisado nesse trabalho. Tal informação ficou guardada na variável r e ele

foi calculado da seguinte maneira:

$$r = 1 + (M \bmod 100) = 1 + (579763 \bmod 100) = 1 + 63 \Rightarrow \boxed{r = 64}$$

Em que *mod* é a operação **resto de divisão**.<sup>1</sup>

Com o índice de início do conjunto de dados a ser analisado e considerando que tal conjunto deveria ter 300 elementos, também foi definido o fim:

$$end = 300 + r - 1 = 300 + 64 - 1 \Rightarrow end = 363$$

Com o início e o fim da janela que define o escopo das análises, foi declarado o `data_group`, que pode ser usado ao longo de todo o código para fazer as outras questões. Também foi definido o `first_ten`, que contém as dez primeiras observações do conjunto de dados do grupo e que será especialmente útil para comparar os cálculos que serão feitos manualmente com os que serão obtidos com o código R.

Daí, foi possível coletar as datas da primeira e da última observação presentes em `data_group`. Elas foram:

- a) Data da primeira observação: 05/03/2011 (ou, no formato internacional, 2011-03-05)
- b) Data da última observação: 29/12/2011 (ou, no formato internacional, 2011-12-29)

**Observação:** Aqui, foram postas as datas da primeira e da última observações, mas essa informação também consta na saída do código fonte produzido. **Recomenda-se que se execute o código `main.r` para ver as informações que são fornecidas na saída.**

## 2 Questão 2

A segunda questão tem o objetivo de caracterizar o conjunto de dados específico do grupo, identificando suas variáveis, calculando medidas estatísticas e analisando a distribuição dos dados. O passo inicial consistiu em preparar o conjunto, estabelecendo a métrica de total de usuários e averiguando a integridade do banco de dados:

```
# 0. Definindo a nova coluna (total_user)
data_group$total_user <- data_group$casual + data_group$registered
first_ten$total_user <- first_ten$casual + first_ten$registered

# 1. Verificacao de valores ausentes (NAs)
has_missing_values = any(is.na(data_group))
```

Com a nova coluna `total_user` estruturada e a inexistência de valores ausentes confirmada pela função `any(is.na())`, as variáveis disponíveis foram classificadas segundo sua natureza:

- a) **Númericas:** `instant`, `temp`, `casual`, `registered` e `total_user`.
- b) **Catégoricas:** `dteday`, `season` e `weathersit`.

Em seguida, procedeu-se ao cálculo das medidas de tendência central para as variáveis numéricas:

---

<sup>1</sup>Em R, essa operação é realizada utilizando `%%`.

```
# 2. Calculando medias e medianas (amostra do grupo)
xn_temp <- mean(data_group$temp)
xn_casual <- mean(data_group$casual)
xn_registered <- mean(data_group$registered)
xn_total_user <- mean(data_group$total_user)

me_temp <- median(data_group$temp)
me_casual <- median(data_group$casual)
me_registered <- median(data_group$registered)
me_total_user <- median(data_group$total_user)
```

**Observação:** As mesmas funções foram aplicadas ao subconjunto `first_ten` para validação das contas manuais. O cálculo da moda não foi implementado, pois as variáveis contínuas não apresentam repetições numéricas com relevância estatística.

Para a análise de dispersão e quartis, a variável `casual` foi isolada:

```
# 3. Analise de quartis e IQR
Q1 <- quantile(data_group$casual, 0.25)
Q2 <- quantile(data_group$casual, 0.5)
Q3 <- quantile(data_group$casual, 0.75)
iqr <- IQR(data_group$casual)

# Limites para identificacao de outliers
lower_bound <- Q1 - 1.5 * iqr
upper_bound <- Q3 + 1.5 * iqr

# Filtragem das observacoes atipicas
outliers <- data_group[data_group$casual < lower_bound | data_group$casual > upper_bound, ]
```

A partir do Intervalo Interquartil (*IQR*), os limites teóricos para a detecção de potenciais valores atípicos (*outliers*) foram fundamentados nas seguintes equações:

$$lower\_bound = Q_1 - 1.5 \cdot IQR$$

$$upper\_bound = Q_3 + 1.5 \cdot IQR$$


As observações fora dessas extremidades foram armazenadas na variável `outliers`, permitindo identificar as datas com utilização atípica de usuários casuais. A distribuição desses dados pode ser visualizada nos gráficos a seguir:

Por fim, a variável indicadora de baixa demanda (`low_usage`) foi definida com base no primeiro quartil da métrica global de usuários:


```
# 5. Definindo a variavel low_usage baseada no Q1 de total_user
Q1_lowusage <- quantile(data_group$total_user, 0.25)
data_group$low_usage <- ifelse(data_group$total_user < Q1_lowusage, 1, 0)

# Proporcao de dias de baixa utilizacao
prop_lu <- nrow(data_group[data_group$low_usage == 1, ]) / nrow(data_group)
```

A condição de baixa utilização obedece à seguinte regra lógica:



**Figura 1:** Boxplot dos usuários casuais.



**Figura 2:** Histograma dos usuários casuais.

$$low\_usage = \begin{cases} 1, & \text{se } total\_user < Q_1 \\ 0, & \text{caso contrário} \end{cases}$$

**Observação:** A fim de garantir a concisão do documento e focar nas interpretações, os valores numéricos exatos apurados nestas etapas (médias, medianas, quartis, quantidades precisas de outliers e proporções) estão disponíveis na saída de execução (*Presenting our results*) do script `main.R`, localizado no repositório.

### 3 Questão 3

### 4 Questão 4