



## **ESTATÍSTICA PARA ENGENHARIA**

### **HOMEWORK 01**

#### **ANÁLISE DE COMPARTILHAMENTO DE BICICLETAS: UMA ABORDAGEM EM ESTATÍSTICA DESCRITIVA**

#### **ALUNOS:**

ALEXANDRE DE AGUIAR MARTINS GRANGEIRO – 578345

BRUNO DELUIZ LAGE – 578342

DANNY SECUNDINO SOUSA FILHO – 579763

SAULO GOMES PINTO – 579493

#### **Acesse nosso GitHub:**

<https://github.com/dannysecundino/homework-01>

## 1 Questão 1

A primeira questão tem o objetivo de definir o escopo de dados a serem utilizados pelo grupo ao longo de toda a análise. Para isso, foi feito um código R que fazia o que foi pedido no enunciado da questão. O código é este:

```
# =====  
# First Question  
# =====  
  
# 1. Defining the highest student number  
# students numbers  
alexandre_sn <- 578345  
bruno_sn <- 578342  
danny_sn <- 579763  
saulo_sn <- 579493  
  
# highest student number  
M <- max(c(alexandre_sn, bruno_sn, danny_sn, saulo_sn)) # 579763  
  
# 2. Defining the start and the end of group's dataset  
# start  
r <- 1 + (M %% 100)      # 64  
  
# end  
end <- 300 + r - 1      # 363  
  
# 3. Defining data_group (ie., the group's dataset)  
# loading the entire file  
all_data <- read.csv("HW1_bike_sharing.csv")  
  
# defining our scope  
data_group <- all_data[r:end, ]      # collect the lines 64-363  
  
# 4. Defining the first 10 observations (we'll use them in the subsequent questions to  
# validate our manual computations)  
first_ten <- data_group[1:10, ]
```

É importante analisar o que, de fato, foi implementado com esse código:

Primeiramente, foram definidas variáveis \*\_sn contendo, cada uma, o valor do número de matrícula de um dos quatro integrantes do grupo. Os valores dos números de matrículas são os seguintes:

- a) Alexandre Grangeiro: 578345;
- b) Bruno Lage: 578342;
- c) Danny Secundino: 579763;
- d) Saulo Gomes: 579493.

Após isso, a variável M foi declarada para guardar o maior número de matrícula dentre os números de matrícula dos membros do grupo. Dessa forma, obtém-se

$$M = 579763$$

Com a informação do maior número de matrícula, foi possível, então, definir o índice inicial do subconjunto de dados a ser analisado nesse trabalho. Tal informação ficou guardada na variável r e ele

foi calculado da seguinte maneira:

$$r = 1 + (M \bmod 100) = 1 + (579763 \bmod 100) = 1 + 63 \Rightarrow \boxed{r = 64}$$

Em que *mod* é a operação **resto de divisão**.<sup>1</sup>

Com o índice de início do conjunto de dados a ser analisado e considerando que tal conjunto deveria ter 300 elementos, também foi definido o fim:

$$end = 300 + r - 1 = 300 + 64 - 1 \Rightarrow end = 363$$

Com o início e o fim da janela que define o escopo das análises, foi declarado o `data_group`, que pode ser usado ao longo de todo o código para fazer as outras questões. Também foi definido o `first_ten`, que contém as dez primeiras observações do conjunto de dados do grupo e que será especialmente útil para comparar os cálculos que serão feitos manualmente com os que serão obtidos com o código R.

Daí, foi possível coletar as datas da primeira e da última observação presentes em `data_group`. Elas foram:

- a) Data da primeira observação: 05/03/2011 (ou, no formato internacional, 2011-03-05)
- b) Data da última observação: 29/12/2011 (ou, no formato internacional, 2011-12-29)

Além disso, vale também apresentar as dez primeiras observações para que a análise ao longo do relatório seja melhor referenciada. Elas estão dispostas na tabela a seguir:

**Tabela 1:** Primeiras dez observações do conjunto `data_group`

| Instant | Data       | Estação | Clima | Temp. | Casual | Registrados | Total | Baixa Utiliz. |
|---------|------------|---------|-------|-------|--------|-------------|-------|---------------|
| 64      | 2011-03-05 | 1       | 2     | 15.8  | 640    | 1437        | 2077  | 0             |
| 65      | 2011-03-06 | 1       | 2     | 15.4  | 114    | 491         | 605   | 1             |
| 66      | 2011-03-07 | 1       | 1     | 10.7  | 244    | 1628        | 1872  | 1             |
| 67      | 2011-03-08 | 1       | 1     | 12.0  | 316    | 1817        | 2133  | 0             |
| 68      | 2011-03-09 | 1       | 2     | 12.1  | 191    | 1700        | 1891  | 0             |
| 69      | 2011-03-10 | 1       | 3     | 16.0  | 46     | 577         | 623   | 1             |
| 70      | 2011-03-11 | 1       | 2     | 13.0  | 247    | 1730        | 1977  | 0             |
| 71      | 2011-03-12 | 1       | 1     | 13.5  | 724    | 1408        | 2132  | 0             |
| 72      | 2011-03-13 | 1       | 1     | 15.8  | 982    | 1435        | 2417  | 0             |
| 73      | 2011-03-14 | 1       | 1     | 13.3  | 359    | 1687        | 2046  | 0             |

As variáveis `total_user` e `low_usage` também foram incluídas na tabela, de modo a consolidar em uma única tabela todos os dados que serão utilizados ao longo das análises seguintes.

**Observação:** Aqui, foram postas as datas da primeira e da última observações, mas essa informação também consta na saída do código fonte produzido. **Recomenda-se que se execute o código `main.r` para ver as informações que são fornecidas na saída.**

<sup>1</sup>Em R, essa operação é realizada utilizando `%%`.

## 2 Questão 2

O objetivo desta seção é caracterizar o conjunto de dados específico do grupo (`data_group`), definido na Questão 1, calcular e interpretar as medidas de tendência central e os quartis das variáveis numéricas relevantes, identificar possíveis valores atípicos e definir a variável `low_usage`. As análises foram realizadas inicialmente de forma manual, com as dez primeiras observações do conjunto (`first_ten`), e, em seguida, verificadas e estendidas às 300 observações do grupo por meio do software R.

### 2.1 Ponto 1 – Caracterização das Variáveis

#### 2.1.1 Classificação das variáveis

- `instant` – Numérica (discreta): índice sequencial que identifica cada registro; assume valores inteiros que apenas ordenam as observações, sem magnitude física associada.
- `dteday` – Categórica (ordinal): representa a data da observação; ainda que expressa em formato numérico (ano-mês-dia), não é submetida a operações aritméticas, apenas ordena os registros no tempo.
- `season` – Categórica (nominal): codifica a estação do ano por meio de rótulos numéricos sem relação de ordem ou magnitude entre si.
- `weathersit` – Categórica (ordinal): codifica a condição meteorológica; os códigos seguem uma ordem crescente de severidade do tempo.
- `temp` – Numérica (contínua): representa a temperatura do dia, em graus Celsius; assume valores reais dentro de um intervalo contínuo.
- `casual` – Numérica (discreta): representa a contagem diária de usuários casuais; assume apenas valores inteiros não negativos.
- `registered` – Numérica (discreta): representa a contagem diária de usuários registrados; assume apenas valores inteiros não negativos.
- `total_user` – Numérica (discreta): variável derivada (`casual + registered`); representa o total diário de usuários do sistema.

#### 2.1.2 Categorias das variáveis categóricas

- `season`: 1 – inverno, 2 – primavera, 3 – verão, 4 – outono (estações do ano no hemisfério norte).
- `weathersit`: 1 – céu limpo, 2 – nublado, 3 – chuva fraca, 4 – chuva forte (ordenadas por severidade da condição meteorológica).

Cabe observar que, no subconjunto de 300 observações do grupo (`data_group`), não há nenhum dia classificado com `weathersit = 4` (chuva forte), de modo que essa categoria, embora definida, não é representada na amostra analisada.

#### 2.1.3 Unidades e significado das variáveis numéricas

- `instant`: sem unidade de medida; identificador sequencial do registro.
- `temp`: graus Celsius; representa a temperatura observada no dia.

- `casual`: pessoas/dia; representa a quantidade de usuários que utilizaram o sistema sem vínculo de cadastro.
- `registered`: pessoas/dia; representa a quantidade de usuários cadastrados que utilizaram o sistema no mesmo dia.
- `total_user`: pessoas/dia; variável derivada que soma `casual` e `registered`, representando o total de usuários do sistema em cada dia observado.

#### 2.1.4 Valores ausentes

A verificação de valores ausentes foi feita por meio da função `is.na()` aplicada a `data_group` (variável `has_missing_values` no código). O resultado obtido foi `FALSE`, isto é, não há valores ausentes em nenhuma das variáveis do conjunto de 300 observações do grupo.

## 2.2 Ponto 2 – Medidas de Tendência Central

As medidas de tendência central foram calculadas para as variáveis numéricas relevantes (`temp`, `casual`, `registered` e `total_user`): média, mediana e, quando aplicável, moda.

A média aritmética  $\bar{x}$  é dada por

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

A mediana  $Me$  corresponde ao valor central do conjunto ordenado (ou à média dos dois valores centrais, quando  $n$  é par):

$$Me = \frac{x_{(n/2)} + x_{(n/2+1)}}{2}, \quad \text{para } n \text{ par}$$

Para o cálculo manual, considera-se

$$n = 10$$

### 2.2.1 Cálculo manual – 10 primeiras observações

A Tabela 2 apresenta os valores de cada variável ordenados de forma crescente, com os dois valores centrais (posições 5 e 6, usados no cálculo da mediana) destacados em negrito.

**Tabela 2:** Valores ordenados (crescente) – 10 primeiras observações

| Posição | temp (°C)   | casual     | registered  | total_user  |
|---------|-------------|------------|-------------|-------------|
| 1       | 10,7        | 46         | 491         | 605         |
| 2       | 12,0        | 114        | 577         | 623         |
| 3       | 12,1        | 191        | 1408        | 1872        |
| 4       | 13,0        | 244        | 1435        | 1891        |
| 5       | <b>13,3</b> | <b>247</b> | <b>1437</b> | <b>1977</b> |
| 6       | <b>13,5</b> | <b>316</b> | <b>1628</b> | <b>2046</b> |
| 7       | 15,4        | 359        | 1687        | 2077        |
| 8       | 15,8        | 640        | 1700        | 2132        |
| 9       | 15,8        | 724        | 1730        | 2133        |
| 10      | 16,0        | 982        | 1817        | 2417        |

**temp**

$$\begin{aligned}\bar{x} &= (10,7 + 12,0 + 12,1 + 13,0 + 13,3 \\ &\quad + 13,5 + 15,4 + 15,8 + 15,8 + 16,0) / 10 \\ &= 137,6 / 10 = 13,76 \text{ }^{\circ}\text{C}\end{aligned}$$

$$Me = \frac{13,3 + 13,5}{2} = 13,40 \text{ }^{\circ}\text{C}$$

**casual**

$$\begin{aligned}\bar{x} &= (46 + 114 + 191 + 244 + 247 \\ &\quad + 316 + 359 + 640 + 724 + 982) / 10 \\ &= 3863 / 10 = 386,30\end{aligned}$$

$$Me = \frac{247 + 316}{2} = 281,50$$

**registered**

$$\begin{aligned}\bar{x} &= (491 + 577 + 1408 + 1435 + 1437 \\ &\quad + 1628 + 1687 + 1700 + 1730 + 1817) / 10 \\ &= 13910 / 10 = 1391,00\end{aligned}$$

$$Me = \frac{1437 + 1628}{2} = 1532,50$$

**total\_user**

$$\begin{aligned}\bar{x} &= (605 + 623 + 1872 + 1891 + 1977 \\ &\quad + 2046 + 2077 + 2132 + 2133 + 2417) / 10 \\ &= 17773 / 10 = 1777,30\end{aligned}$$

$$Me = \frac{1977 + 2046}{2} = 2011,50$$

Os valores calculados manualmente coincidem com os obtidos por meio do código R (variáveis `xn_first10_*` e `me_first10_*`), conforme resumido na Tabela 3:

**Tabela 3:** Medidas de tendência central – 10 primeiras observações

| Variável   | Média    | Mediana  | Moda |
|------------|----------|----------|------|
| temp       | 13,76 °C | 13,40 °C | –    |
| casual     | 386,30   | 281,50   | –    |
| registered | 1391,00  | 1532,50  | –    |
| total_user | 1777,30  | 2011,50  | –    |

Os mesmos cálculos foram estendidos às 300 observações do grupo (variáveis `xn_*` e `me_*`):

Para nenhuma das quatro variáveis numéricas há um valor que se repita com frequência relevante, de modo que a moda não constitui uma medida significativa nesse conjunto de dados, tanto nas 10 primeiras observações quanto nas 300 observações do grupo.

**Tabela 4:** Medidas de tendência central – 300 observações do grupo

| Variável   | Média    | Mediana  | Moda |
|------------|----------|----------|------|
| temp       | 22,11 °C | 22,20 °C | –    |
| casual     | 786,92   | 691,50   | –    |
| registered | 3025,08  | 3238,50  | –    |
| total_user | 3812,00  | 4067,50  | –    |

Nas 300 observações, observa-se que a média de `casual` (786,92) é superior à sua mediana (691,50), indicando uma distribuição assimétrica à direita: a maioria dos dias apresenta uso casual moderado, enquanto um número menor de dias com uso muito elevado eleva o valor da média. Padrão semelhante, embora menos acentuado, é observado nas 10 primeiras observações. Já para `registered` e `total_user`, a média é ligeiramente inferior à mediana, sugerindo leve assimetria à esquerda, compatível com a existência de alguns dias de uso registrado bastante baixo (possivelmente fins de semana ou feriados) que reduzem o valor médio. A variável `temp` apresenta média e mediana muito próximas nas 300 observações (22,11 °C e 22,20 °C), o que é coerente com o período coberto pela amostra do grupo, que se estende de março a dezembro de 2011, abrangendo estações de temperatura variada e resultando em uma distribuição aproximadamente simétrica.

## 2.3 Ponto 3 – Quartis e Valores Atípicos

A variável escolhida para a análise de quartis e valores atípicos foi `casual` (número de usuários casuais por dia). A escolha se justifica por essa variável representar o quantitativo de usuários que utilizam o sistema de forma espontânea, sem vínculo de registro (`registered`). Por não estarem associados a um cadastro fixo, esses usuários refletem de maneira mais direta a demanda ocasional pelo serviço, tornando essa variável adequada para identificar dias com comportamento de uso atípico em relação ao padrão observado.

Os quartis  $Q_1$ ,  $Q_2$  e  $Q_3$  dividem o conjunto ordenado de dados em quatro partes de igual tamanho. O intervalo interquartil é dado por

$$IQR = Q_3 - Q_1$$

Os limites inferior e superior para identificação de possíveis valores atípicos, segundo o critério do IQR, são dados por

$$LI = Q_1 - 1,5 \cdot IQR \quad LS = Q_3 + 1,5 \cdot IQR$$

### 2.3.1 Cálculo manual dos quartis – 10 primeiras observações

Para o cálculo manual, com  $N = 10$ , a posição de cada quartil no conjunto ordenado é obtida por

$$\text{posição}(Q_1) = \frac{N+1}{4} = \frac{11}{4} = 2,75$$

$$\text{posição}(Q_2) = \frac{N+1}{2} = \frac{11}{2} = 5,50$$

$$\text{posição}(Q_3) = \frac{3(N+1)}{4} = \frac{33}{4} = 8,25$$

Com os valores de `casual` já ordenados na Tabela 2 (46, 114, 191, 244, 247, 316, 359, 640, 724,

982), cada quartil é obtido por interpolação linear entre as posições inteiras adjacentes:

$$Q_1 = 114 + 0,75 \cdot (191 - 114) = 171,75$$

$$Q_2 = 247 + 0,5 \cdot (316 - 247) = 281,50$$

$$Q_3 = 640 + 0,25 \cdot (724 - 640) = 661,00$$

$$IQR = Q_3 - Q_1 = 661,00 - 171,75 = 489,25$$

$$LI = 171,75 - 1,5 \cdot 489,25 = -562,125 \quad LS = 661,00 + 1,5 \cdot 489,25 = 1394,875$$

Como todos os valores de `casual` nas 10 primeiras observações estão contidos no intervalo  $[-562,125; 1394,875]$ , nenhuma observação é classificada como atípica também pelo cálculo manual, resultado consistente com o obtido via R.

Para as 10 primeiras observações (variáveis `Q1_f10`, `Q2_f10`, `Q3_f10`, `iqr_f10`, `lower_bound_f10`, `upper_bound_f10` e `outliers_f10` no código):

**Tabela 5:** Quartis e limites de valores atípicos de `casual` – 10 primeiras observações

|                 |         |
|-----------------|---------|
| $Q_1$           | 204,25  |
| $Q_2$           | 281,50  |
| $Q_3$           | 569,75  |
| $IQR$           | 365,50  |
| Limite inferior | -344,00 |
| Limite superior | 1118,00 |

Observa-se que os valores de  $Q_1$  e  $Q_3$  calculados manualmente (171,75 e 661,00) diferem dos valores obtidos pela função `quantile()` do R (204,25 e 569,75). Essa diferença decorre da convenção de interpolação adotada por cada método: o cálculo manual utiliza a posição  $\frac{N+1}{4}$  (equivalente ao tipo 6 de quantil), enquanto a função `quantile()` do R utiliza, por padrão, a posição  $1 + (n - 1) \cdot p$  (tipo 7). Já a mediana ( $Q_2 = 281,50$ ) coincide exatamente entre os dois métodos, pois ambas as convenções resultam na mesma posição central ( $\frac{N+1}{2} = 5,5$ ) para esse caso. Em ambos os métodos, entretanto, a conclusão quanto à ausência de valores atípicos nas 10 primeiras observações se mantém.

O mesmo procedimento (via R) foi aplicado às 300 observações do grupo (variáveis `Q1`, `Q2`, `Q3`, `iqr`, `lower_bound`, `upper_bound` e `outliers`):

**Tabela 6:** Quartis e limites de valores atípicos de `casual` – 300 observações do grupo

|                 |         |
|-----------------|---------|
| $Q_1$           | 376,75  |
| $Q_2$           | 691,50  |
| $Q_3$           | 949,75  |
| $IQR$           | 573,00  |
| Limite inferior | -482,75 |
| Limite superior | 1809,25 |

Nas 10 primeiras observações, nenhum dia foi classificado como valor atípico: todos os valores de `casual` nesse subconjunto encontram-se dentro do intervalo  $[-344,00; 1118,00]$ . Já nas 300 observações do grupo, foram identificados 18 dias com valor de `casual` acima do limite superior (1809,25) – não houve valores abaixo do limite inferior, o que é esperado, já que esse limite é negativo e `casual` não assume valores negativos. As datas classificadas como atípicas estão listadas na Tabela 7.

Observa-se que todas as datas atípicas se concentram entre final de abril e meados de outubro,


**Tabela 7:** Dias classificados como valores atípicos de *casual* – 300 observações do grupo

| Data       | <i>casual</i> | Data       | <i>casual</i> |
|------------|---------------|------------|---------------|
| 30/04/2011 | 1965          | 09/07/2011 | 1988          |
| 21/05/2011 | 2258          | 16/07/2011 | 2418          |
| 28/05/2011 | 2001          | 17/07/2011 | 2006          |
| 29/05/2011 | 2355          | 20/08/2011 | 1914          |
| 04/06/2011 | 1869          | 03/09/2011 | 1935          |
| 26/06/2011 | 1920          | 04/09/2011 | 2521          |
| 02/07/2011 | 2204          | 08/10/2011 | 2235          |
| 03/07/2011 | 2282          | 09/10/2011 | 2397          |
| 04/07/2011 | 3065          | 15/10/2011 | 1899          |


período de clima mais ameno no hemisfério norte, e incluem finais de semana e datas próximas a feriados (como 04/07/2011, Dia da Independência dos EUA, e o final de semana de 28–29/05/2011, próximo ao feriado de Memorial Day). Esse padrão é coerente com a natureza da variável *casual*: por não exigir cadastro, o uso casual do sistema tende a ser mais sensível a condições favoráveis de lazer (bom tempo, folgas e feriados), o que explica a ocorrência de picos pontuais de demanda muito acima do padrão típico. Esses valores atípicos são relevantes para a análise do sistema por sinalizarem dias de pico de demanda que podem exigir redistribuição adicional de bicicletas ou reforço operacional.

## 2.4 Ponto 4 – Histograma e Boxplot

Para a variável *casual*, foram construídos histogramas e boxplots, tanto para as 10 primeiras observações quanto para as 300 observações do grupo, permitindo analisar forma, dispersão, assimetria e a presença de valores atípicos.


**Figura 1:** Distribuição de *casual* – 10 primeiras observações

Nas 10 primeiras observações, os valores de *casual* variam de 46 a 982 usuários por dia. O histograma exibe uma distribuição irregular, esperada dado o tamanho reduzido da amostra, com leve concentração nos valores mais baixos e uma cauda à direita. O boxplot correspondente não apresenta pontos além dos limites dos whiskers, em concordância com a ausência de valores atípicos apontada no Ponto 3, mas já evidencia uma mediana deslocada para a parte inferior da caixa, um primeiro indício de assimetria à direita.



**Figura 2:** Distribuição de `casual` – 300 observações do grupo

Nas 300 observações do grupo, o histograma revela uma distribuição unimodal com assimetria positiva (à direita) bem mais evidente: a maior parte dos dias concentra-se na faixa entre aproximadamente 200 e 950 usuários casuais (intervalo entre  $Q_1$  e  $Q_3$ ), com uma cauda longa se estendendo até o valor máximo de 3065. O boxplot confirma esse padrão – a mediana está deslocada para a parte inferior da caixa, o whisker superior é bem mais longo que o inferior, e os 18 valores atípicos aparecem representados como pontos isolados acima do limite superior. De forma geral, o histograma evidencia melhor a forma global da distribuição (concentração, cauda e multimodalidade, caso existisse), enquanto o boxplot evidencia de forma mais direta e quantitativa os quartis, a mediana e a posição exata dos valores atípicos.

## 2.5 Ponto 5 – Variável `low_usage`

Com base no primeiro quartil  $Q_1$  de `total_user`, foi definida a variável binária `low_usage`, segundo o critério

$$\text{low\_usage} = \begin{cases} 1, & \text{se } \text{total\_user} < Q_1 \\ 0, & \text{caso contrário} \end{cases}$$

Diferentemente da escolha de `casual` feita no Ponto 3 – em que a variável foi selecionada pelo grupo entre as opções relevantes –, aqui a variável de referência é `total_user` porque o próprio critério de definição de `low_usage`, apresentado no enunciado, utiliza explicitamente o primeiro quartil dessa variável como limiar (Equação anterior).

### 2.5.1 Cálculo manual de $Q_1$ – 10 primeiras observações

Assim como no Ponto 3, a posição do primeiro quartil no conjunto ordenado é obtida por

$$\text{posição}(Q_1) = \frac{N+1}{4} = \frac{11}{4} = 2,75, \quad N = 10$$

Com os valores de `total_user` já ordenados na Tabela 2 (605, 623, 1872, 1891, 1977, 2046, 2077,

2132, 2133, 2417), o quartil é obtido por interpolação linear entre a 2ª e a 3ª posições:

$$Q_1 = 623 + 0,75 \cdot (1872 - 623) = 1559,75$$

Esse valor difere do obtido pela função `quantile()` do R ( $Q_1 = 1876,75$ ) pela mesma razão discutida no Ponto 3: a convenção de interpolação da posição  $\frac{N+1}{4}$  (tipo 6) diverge da convenção padrão do R,  $1 + (n - 1) \cdot p$  (tipo 7). Usando o valor manual (1559,75), apenas 2 das 10 primeiras observações seriam classificadas como `low_usage` (20%), contra as 3 observações (30%) obtidas com o valor verificado em R. Os resultados apresentados a seguir seguem o valor calculado via R, em consonância com a metodologia adotada no restante do relatório.

Para as 10 primeiras observações, o valor de referência foi  $Q_1 = 1876,75$  (variável `Q1_lowusage_f10`), resultando em 3 dias classificados como de baixa utilização, correspondendo a uma proporção de 30% (variável `prop_lu_f10`).

Para as 300 observações do grupo, o valor de referência foi  $Q_1 = 3116,50$  (variável `Q1_lowusage`), resultando em 75 dias classificados como de baixa utilização, correspondendo a uma proporção de 25% (variável `prop_lu`).

Por construção, a proporção de dias classificados como `low_usage` tende a se aproximar de 25%, já que o critério utiliza exatamente o primeiro quartil da própria distribuição de `total_user` – o que é confirmado pelo resultado obtido nas 300 observações do grupo. Na amostra reduzida de 10 observações, a proporção observada (30%) se afasta ligeiramente desse valor teórico em razão do tamanho pequeno da amostra, que torna a posição exata do quartil mais sensível a poucos valores e a possíveis empates. No contexto do sistema, os dias marcados como `low_usage` correspondem tipicamente a condições que desestimulam o uso das bicicletas – como baixas temperaturas, condições meteorológicas desfavoráveis ou dias da semana com menor mobilidade –, constituindo uma variável útil para segmentar e investigar os fatores associados à baixa demanda do sistema.

### 3 Questão 3

O objetivo desta seção é investigar as características associadas aos dias de menor utilização do sistema, a partir da variável `low_usage` definida na Questão 2. Assim como nas seções anteriores, os cálculos foram feitos manualmente com as dez primeiras observações (`first_ten`) e verificados e estendidos às 300 observações do grupo (`data_group`) por meio do R. Para as 300 observações, o limiar de baixa utilização é  $Q_1 = 3116,50$  (variável `Q1_lowusage`); para as 10 primeiras,  $Q_1 = 1876,75$  (variável `Q1_lowusage_f10`), ambos referentes a `total_user`. O desvio padrão calculado é o amostral (denominador  $n - 1$ ), o mesmo da função `sd()` do R.

#### 3.1 Ponto 1 – Utilização por Estação do Ano

Para cada estação foram calculados a média, a mediana e o desvio padrão de `total_user`, além da proporção de dias classificados como `low_usage`.

##### 3.1.1 Cálculo manual – 10 primeiras observações

As 10 primeiras observações (05/03/2011 a 14/03/2011) pertencem todas à estação 1 (inverno). Portanto, as demais estações não possuem observações nesse subconjunto e suas medidas são indefinidas. A Tabela 8 apresenta os dados, com `low_usage` calculado com  $Q_1 = 1876,75$ .

**Tabela 8:** Total de usuários e indicador de baixo uso – 10 primeiras observações de inverno

| Instant | Data       | Estação | casual | registered | total_user | low_usage |
|---------|------------|---------|--------|------------|------------|-----------|
| 64      | 2011-03-05 | 1       | 640    | 1437       | 2077       | 0         |
| 65      | 2011-03-06 | 1       | 114    | 491        | 605        | 1         |
| 66      | 2011-03-07 | 1       | 244    | 1628       | 1872       | 1         |
| 67      | 2011-03-08 | 1       | 316    | 1817       | 2133       | 0         |
| 68      | 2011-03-09 | 1       | 191    | 1700       | 1891       | 0         |
| 69      | 2011-03-10 | 1       | 46     | 577        | 623        | 1         |
| 70      | 2011-03-11 | 1       | 247    | 1730       | 1977       | 0         |
| 71      | 2011-03-12 | 1       | 724    | 1408       | 2132       | 0         |
| 72      | 2011-03-13 | 1       | 982    | 1435       | 2417       | 0         |
| 73      | 2011-03-14 | 1       | 359    | 1687       | 2046       | 0         |

##### Média

$$\bar{x} = \frac{2077 + 605 + 1872 + 2133 + 1891 + 623 + 1977 + 2132 + 2417 + 2046}{10} = \frac{17773}{10} = 1777,30$$

**Mediana** Com os valores ordenados (605, 623, 1872, 1891, 1977, 2046, 2077, 2132, 2133, 2417) e  $n = 10$  par,

$$Me = \frac{x_{(5)} + x_{(6)}}{2} = \frac{1977 + 2046}{2} = 2011,50$$

##### Desvio padrão amostral

$$\begin{aligned} \sum_{i=1}^{10} (x_i - \bar{x})^2 &= 89820,09 + 1374287,29 + 8968,09 + 126522,49 + 12927,69 \\ &+ 1332409,49 + 39880,09 + 125811,09 + 409216,09 + 72199,69 = 3592042,10 \end{aligned}$$

$$s = \sqrt{\frac{3592042,10}{10 - 1}} = \sqrt{399115,79} \approx 631,76$$

**Proporção de low\_usage** Os instants 65, 66 e 69 têm `total_user < 1876,75`:

$$p = \frac{0 + 1 + 1 + 0 + 0 + 1 + 0 + 0 + 0 + 0}{10} = \frac{3}{10} = 0,30$$


Os valores calculados manualmente coincidem com os obtidos por meio do código R (variáveis `xn_winter_f10`, `me_winter_f10`, `sd_winter_f10` e `prop_lu_winter_f10`): média 1777,30, mediana 2011,50,  $s = 631,7561$  e proporção 0,3. Para primavera, verão e outono, as variáveis correspondentes resultam em NaN/NA, e o código evita o boxplot desses grupos vazios.

### 3.1.2 Resultados para as 300 observações do grupo

O mesmo procedimento foi aplicado às 300 observações (variáveis `xn_*`, `me_*`, `sd_*` e `prop_lu_*` de cada estação). O inverno tem 25 dias no recorte do grupo (16 dias de março e 9 de dezembro); primavera, verão e outono têm 92, 94 e 89 dias, respectivamente.


**Tabela 9:** Utilização do sistema por estação – 300 observações do grupo

| Estação   | <i>n</i> | Média   | Mediana | Desv. padrão | Prop. low_usage |
|-----------|----------|---------|---------|--------------|-----------------|
| Inverno   | 25       | 2019,92 | 2132,00 | 743,46       | 0,9200          |
| Primavera | 92       | 3775,17 | 4085,50 | 1138,90      | 0,2609          |
| Verão     | 94       | 4464,36 | 4615,50 | 798,35       | 0,0426          |
| Outono    | 89       | 3664,46 | 3717,00 | 983,01       | 0,2697          |



**Figura 3:** Boxplot de `total_user` – 10 primeiras observações (inverno)

O verão apresenta a maior média (4464,36) e a maior mediana (4615,50), com apenas 4,26% de dias de baixa utilização, e é a estação de menor dispersão em torno da média (desvio padrão de 798,35). O inverno é o oposto: menor média (2019,92) e 92% dos dias abaixo do limiar  $Q_1 = 3116,50$  (23 dos 25 dias), ou seja, quase todo dia de inverno é de baixa utilização. Primavera e outono ficam em posição intermediária, com proporções de `low_usage` próximas de 26–27%, valores parecidos com os 25% esperados para o conjunto todo. A primavera tem o maior desvio padrão (1138,90), possivelmente dado que está entre o inverno (de menor uso) e o verão (de maior uso). Em todas as estações a média é



**Figura 4:** Boxplot de `total_user` por estação – 300 observações do grupo

inferior à mediana, o que sugere leve assimetria à esquerda, provocada por dias isolados de uso muito baixo. O inverno tem apenas 25 dias no recorte do grupo, de modo que suas medidas são menos estáveis que as das demais estações.

### 3.2 Ponto 2 – Utilização por Condição Meteorológica

Para cada condição (1 – céu limpo, 2 – nublado, 3 – chuva fraca, 4 – chuva forte), foram calculados a média e o desvio padrão de `total_user` e a proporção de dias de `low_usage`. O código calcula também a mediana, que foi incluída na análise das 300 observações.

#### 3.2.1 Cálculo manual – 10 primeiras observações

Nas 10 primeiras observações, há 5 dias de céu limpo (instants 66, 67, 71, 72 e 73), 4 nublados (64, 65, 68 e 70), 1 de chuva fraca (69) e nenhum de chuva forte.

**Céu limpo** ( $n = 5$ ; valores 1872, 2133, 2132, 2417, 2046):

$$\bar{x} = \frac{10600}{5} = 2120,00$$

$$\sum (x_i - \bar{x})^2 = 61504 + 169 + 144 + 88209 + 5476 = 155502 \quad s = \sqrt{\frac{155502}{4}} = \sqrt{38875,5} \approx 197,17$$

$$p = \frac{1}{5} = 0,20 \quad (\text{apenas o instant 66, com } 1872 < 1876,75)$$

**Nublado** ( $n = 4$ ; valores 2077, 605, 1891, 1977):

$$\bar{x} = \frac{6550}{4} = 1637,50$$

$$\sum (x_i - \bar{x})^2 = 193160,25 + 1066056,25 + 64262,25 + 115260,25 = 1438739 \quad s = \sqrt{\frac{1438739}{3}} \approx 692,52$$

$$p = \frac{1}{4} = 0,25 \quad (\text{apenas o instant 65, com } 605 < 1876,75)$$

**Chuva fraca** ( $n = 1$ ; valor 623):  $\bar{x} = 623,00$  e  $p = 1,00$ . Com  $n = 1$ , o desvio padrão amostral é indefinido, pois o denominador  $n - 1$  é nulo (NA no R).

**Chuva forte** ( $n = 0$ ): não há observações, logo média, desvio padrão e proporção são indefinidos.


**Tabela 10:** Utilização por condição meteorológica – 10 primeiras observações

| Condição    | $n$ | Média   | Desv. padrão | Prop. low_usage |
|-------------|-----|---------|--------------|-----------------|
| Céu limpo   | 5   | 2120,00 | 197,17       | 0,20            |
| Nublado     | 4   | 1637,50 | 692,52       | 0,25            |
| Chuva fraca | 1   | 623,00  | –            | 1,00            |
| Chuva forte | 0   | –       | –            | –               |

Os valores coincidem com os do código R (variáveis `xn*_f10`, `sd*_f10` e `prop_lu*_f10` de cada condição). Com grupos de tamanhos 5, 4 e 1, não há valores suficientes para fazer comparações sem distorções.

#### 3.2.2 Resultados para as 300 observações do grupo


Nas 300 observações, há 185 dias de céu limpo, 101 nublados e 14 de chuva fraca. Não há nenhum dia de chuva forte (`weathersit = 4`), como já observado no Ponto 1 da Questão 2, e por isso essa condição não pode ser analisada.



**Figura 5:** Boxplot de `total_user` por condição meteorológica – 10 primeiras observações


**Tabela 11:** Utilização por condição meteorológica – 300 observações do grupo

| Condição    | <i>n</i> | Média   | Mediana | Desv. padrão | Dias <code>low_usage</code> | Proporção |
|-------------|----------|---------|---------|--------------|-----------------------------|-----------|
| Céu limpo   | 185      | 4149,83 | 4381,00 | 990,24       | 26                          | 0,1405    |
| Nublado     | 101      | 3477,98 | 3740,00 | 1085,68      | 35                          | 0,3465    |
| Chuva fraca | 14       | 1757,57 | 1829,50 | 793,95       | 14                          | 1,0000    |
| Chuva forte | 0        | –       | –       | –            | –                           | –         |



**Figura 6:** Boxplot de `total_user` por condição meteorológica – 300 observações do grupo

A média de `total_user` cai à medida que a condição meteorológica piora: 4149,83 (céu limpo), 3477,98 (nublado) e 1757,57 (chuva fraca), com medianas na mesma ordem. Em chuva fraca, a média é menos da metade da observada em dias de céu limpo. A proporção de `low_usage` reforça o padrão: 14,05% em dias de céu limpo, 34,65% em dias nublados e 100% em dias de chuva fraca, isto é, todos os 14 dias de chuva fraca estão abaixo do limiar  $Q_1 = 3116,50$ . Os desvios padrão são de magnitude semelhante (entre 794 e 1086), com a maior variabilidade nos dias nublados. Como o grupo de chuva fraca tem apenas 14 dias e não há dias de chuva forte, as conclusões sobre condições adversas devem ser tomadas com cautela.



**Figura 7:** Proporção de dias de baixa utilização por condição meteorológica

### 3.3 Ponto 3 – Relação entre Temperatura e total\_user

A associação linear entre a temperatura ( $x$ , em °C) e `total_user` ( $y$ ) foi medida pelo coeficiente de correlação:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

#### 3.3.1 Cálculo manual – 10 primeiras observações

Com  $\bar{x} = 13,76$  e  $\bar{y} = 1777,30$ , obtém-se a Tabela 12.

**Tabela 12:** Cálculo auxiliar da correlação – 10 primeiras observações

| Instant     | $x_i$ | $y_i$ | $x_i - \bar{x}$ | $y_i - \bar{y}$ | $(x_i - \bar{x})^2$ | $(y_i - \bar{y})^2$ | $(x_i - \bar{x})(y_i - \bar{y})$ |
|-------------|-------|-------|-----------------|-----------------|---------------------|---------------------|----------------------------------|
| 64          | 15,8  | 2077  | 2,04            | 299,7           | 4,1616              | 89820,09            | 611,388                          |
| 65          | 15,4  | 605   | 1,64            | -1172,3         | 2,6896              | 1374287,29          | -1922,572                        |
| 66          | 10,7  | 1872  | -3,06           | 94,7            | 9,3636              | 8968,09             | -289,782                         |
| 67          | 12,0  | 2133  | -1,76           | 355,7           | 3,0976              | 126522,49           | -626,032                         |
| 68          | 12,1  | 1891  | -1,66           | 113,7           | 2,7556              | 12927,69            | -188,742                         |
| 69          | 16,0  | 623   | 2,24            | -1154,3         | 5,0176              | 1332409,49          | -2585,632                        |
| 70          | 13,0  | 1977  | -0,76           | 199,7           | 0,5776              | 39880,09            | -151,772                         |
| 71          | 13,5  | 2132  | -0,26           | 354,7           | 0,0676              | 125811,09           | -92,222                          |
| 72          | 15,8  | 2417  | 2,04            | 639,7           | 4,1616              | 409216,09           | 1304,988                         |
| 73          | 13,3  | 2046  | -0,46           | 268,7           | 0,2116              | 72199,69            | -123,602                         |
| <b>Soma</b> |       |       |                 |                 | <b>32,104</b>       | <b>3592042,10</b>   | <b>-4063,980</b>                 |

$$r = \frac{-4063,98}{\sqrt{32,104 \times 3592042,10}} = \frac{-4063,98}{\sqrt{115318919,6}} \approx \frac{-4063,98}{10738,67} \approx -0,3784$$

Esse valor coincide com o obtido no código R (variável `temp_tu_cor_f10` = -0.3784437). Nas 10 primeiras observações, a associação é moderada e de sinal negativo, contrariando a expectativa de que dias mais quentes tenham mais usuários. Isso pode muito bem decorrer do tamanho reduzido da amostra: os dois menores valores de `total_user` (605 e 623) ocorrem em dias de temperatura relativamente alta para o subconjunto (15,4 °C e 16,0 °C), sendo o segundo um dia de chuva fraca. Nesse subconjunto, outros fatores que não a temperatura dominam a variação do uso.


#### 3.3.2 Resultados para as 300 observações do grupo

Para as 300 observações, temos do código (variável `temp_tu_cor`)


$$r = 0,6376 \quad r^2 \approx 0,4065$$

O coeficiente  $r = 0,6376$  indica uma associação positiva e de intensidade moderada a forte: dias mais quentes tendem a apresentar maior número total de usuários. O coeficiente de determinação,  $r^2 \approx 0,41$ , indica que cerca de 41% da variação de `total_user` é explicada linearmente pela temperatura, restando aproximadamente 59% associado a outros fatores.

No entanto, o coeficiente de correlação possui algumas limitações. Vale notar que a temperatura está fortemente associada à estação do ano e às condições meteorológicas, que também afetam o uso do sistema. Parte da correlação pode refletir esses fatores em vez de ser um efeito direto da temperatura e,



**Figura 8:** Diagrama de dispersão entre `temp` e `total_user` – 10 primeiras observações



**Figura 9:** Diagrama de dispersão entre `temp` e `total_user` – 300 observações do grupo

então, não haveria causalidade. Além disso, o coeficiente mede apenas relações lineares entre os dados. Caso a associação entre usuários e temperatura seja curva, com alguma saturação em temperaturas mais altas, o coeficiente de correlação não consegue representar muito bem essa dinâmica, dada sua natureza linear.

### 3.4 Ponto 4 – Características Mais Associadas à Utilização do Sistema

Com base nos resultados dos Pontos 1, 2 e 3, as duas características que parecem estar mais fortemente associadas à utilização do sistema são a estação do ano e a condição meteorológica.

A Tabela 9 mostra a maior amplitude entre grupos dentre todas as características analisadas: a média de `total_user` varia de 2019,92 (inverno) a 4464,36 (verão), uma diferença de mais de 2400 usuários por dia. Ademais, a proporção de dias de baixa utilização varia de 4,26% no verão a 92,00% no inverno. Essa diferença de quase 88 pontos percentuais entre os extremos é extremamente expressiva e, portanto, um fortíssimo indício de que a estação do ano é o fator isolado mais discriminante entre dias de alta e baixa utilização do sistema.

Já a Tabela 11 mostra outro padrão observável: a média de `total_user` cai de 4149,83 (céu limpo) para 1757,57 (chuva fraca), e a proporção de dias de `low_usage` sobe de 14,05% para 100,00%. Em outras palavras, todos os 14 dias de chuva fraca do grupo são classificados como de baixa utilização. Esse resultado permite inferir que a condição climática interfere quase deterministicamente na taxa de utilização do sistema.

Quanto à temperatura, é possível dizer que apresenta associação relevante com `total_user` ( $r = 0,6376$  nas 300 observações), mas essa correlação é de intensidade moderada e explica apenas cerca de 41% da variância de `total_user` ( $r^2 \approx 0,41$ ), contra os efeitos muito mais acentuados observados por estação e por condição meteorológica. Além disso, a temperatura está intimamente correlacionada com a própria estação do ano e com a condição meteorológica (dias quentes tendem a ser dias de verão e de céu limpo), de modo que parte do efeito atribuído à temperatura é, em boa medida, um reflexo desses dois outros fatores, e não um efeito independente.

Assim, estação do ano e condição meteorológica se destacam como as características mais associadas à utilização do sistema dada a proporção de dias classificados como `low_usage`, que nos dois casos varia de valores muito baixos (4,26% no verão; 14,05% em dias de céu limpo) a valores extremos (92,00% no inverno; 100,00% em dias de chuva fraca).

## 4 Questão 4

Esta seção aprofunda os resultados das Questões 2 e 3: analisa a série temporal de `total_user`, examina as duas variáveis selecionadas (estação do ano e condição meteorológica) com novas visualizações, estratifica a relação entre temperatura e utilização por grupo `low_usage` e encerra com uma conclusão geral.

### 4.1 Ponto 1 – Série Temporal de `total_user`

#### 4.1.1 Série temporal – 10 primeiras observações

A série temporal da Figura 10 mostra a variação diária de `total_user` nas primeiras dez observações (março de 2011). A demanda começa em 2077 usuários, cai para 605 em 06/03/2011 (domingo com chuva), volta ao patamar de 1800–2100 nos dias úteis, recua para 623 em 10/03/2011 (chuva fraca) e atinge o pico local de 2417 em 13/03/2011.




Figura 10: Série temporal de `total_user` – 10 primeiras observações

#### 4.1.2 Série temporal – 300 observações do grupo




Figura 11: Série temporal de `total_user` – 300 observações do grupo

A Figura 11 apresenta a série completa. Três padrões se destacam:


- Sazonalidade:** A demanda sobe ao longo da primavera, atinge o pico no verão e início do outono (4000–5500 usuários/dia, com máximo de 6043 em 04/07/2011) e cai continuamente a partir de outubro, chegando abaixo de 2000 em dezembro.
- Ciclos semanais:** Sobre a tendência sazonal, há uma oscilação regular em dentes de serra: dias úteis concentram os usuários cadastrados (`registered`), enquanto fins de semana registram menor demanda.
- Quedas pontuais por clima:** Mesmo no verão, episódios isolados derrubam o uso abaixo de 1000–2000 usuários. Cada um desses pontos corresponde a dias de chuva fraca ou condições adversas, evidenciando a sensibilidade do sistema ao tempo.

## 4.2 Ponto 2 – Aprofundamento das Características Seleccionadas

As duas características seleccionadas no Ponto 4 da Questão 3 foram **estação do ano** (season) e **condição meteorológica** (weathersit). Para cada uma, a análise é aprofundada com novas visualizações e medidas estatísticas adicionais.

### 4.2.1 Estação do Ano

Na Questão 3, cada estação foi apresentada em boxplots separados, dificultando a comparação direta. Aqui, usou-se um painel unificado com boxplot comparativo (Figura 12a), gráfico de barras das médias (Figura 12b) e proporção de dias de baixo uso (Figura 12c).



**Figura 12:** Visualizações integradas de `total_user` por estação do ano – 300 observações do grupo

Para quantificar a dispersão relativa e a estabilidade da demanda em cada estação, calculou-se o **coeficiente de variação** ( $CV = s/\bar{x}$ , gerado no código R na variável `cv_season`), além da amplitude entre as médias e da proporção de dias de baixa utilização, consolidados na Tabela 13.


**Tabela 13:** Estatísticas aprofundadas de `total_user` por estação do ano – 300 observações

| Estação   | <i>n</i> | Média ( $\bar{x}$ ) | Mediana ( <i>Me</i> ) | Desv. Padrão ( <i>s</i> ) | CV (%) | Prop. low usage |
|-----------|----------|---------------------|-----------------------|---------------------------|--------|-----------------|
| Inverno   | 25       | 2019,92             | 2132,00               | 743,46                    | 36,81% | 92,00%          |
| Primavera | 92       | 3775,17             | 4085,50               | 1138,90                   | 30,17% | 26,09%          |
| Verão     | 94       | 4464,36             | 4615,50               | 798,35                    | 17,88% | 4,26%           |
| Outono    | 89       | 3664,46             | 3717,00               | 983,01                    | 26,83% | 26,97%          |

A amplitude entre as médias extremas é  $\Delta\bar{x} = 2444,44$  usuários/dia, com o volume médio no verão superando o do inverno em 121,0%. O CV revela ainda que o verão é a estação mais estável ( $CV = 17,88\%$ ), ao passo que o inverno é o mais disperso relativamente ( $CV = 36,81\%$ ), seguido da primavera (30,17%). Além disso, a proporção de dias de baixo uso é de 92,00% no inverno contra apenas 4,26% no verão, demonstrando o forte contraste sazonal. O boxplot confirma visualmente: a caixa interquartil do verão ( $Q_1 \approx 4149$ ) praticamente não se sobrepõe à do inverno ( $Q_3 \approx 2423$ ).

### 4.2.2 Condição Meteorológica

Para a condição meteorológica, adotou-se o **boxplot comparativo direto** das três categorias presentes na amostra (Figura 13a) e o **gráfico de barras das médias** (Figura 13b).



**Figura 13:** Visualizações integradas de `total_user` por condição meteorológica – 300 observações do grupo

Como medidas estatísticas complementares, calcularam-se o coeficiente de variação ( $CV = s/\bar{x}$ , variável `cv_weather`) e a retração percentual média em relação aos dias de céu limpo (variável `pct_change_weather`, Tabela 14).

**Tabela 14:** Estatísticas aprofundadas de `total_user` por condição meteorológica – 300 observações

| Condição    | <i>n</i> | Média ( $\bar{x}$ ) | Mediana ( <i>Me</i> ) | Desv. Padrão ( <i>s</i> ) | CV (%) | Variação vs. Céu Limpo |
|-------------|----------|---------------------|-----------------------|---------------------------|--------|------------------------|
| Céu limpo   | 185      | 4149,83             | 4381,00               | 990,24                    | 23,86% | –                      |
| Nublado     | 101      | 3477,98             | 3740,00               | 1085,68                   | 31,22% | –16,19%                |
| Chuva fraca | 14       | 1757,57             | 1829,50               | 793,95                    | 45,17% | –57,65%                |
| Chuva forte | 0        | –                   | –                     | –                         | –      | –                      |

Dias nublados reduzem a média em 16,19% em relação ao céu limpo. A chuva fraca, porém, representa uma queda severa de 57,65% ( $\Delta\bar{x} = -2392,26$  usuários/dia), apresentando a maior dispersão relativa ( $CV = 45,17\%$ ). Além disso, 100% dos dias com chuva fraca foram classificados como de baixa utilização (`low_usage`). O boxplot reforça esse resultado: o  $Q_3$  de dias de chuva fraca é inferior ao  $Q_1$  de dias de céu limpo, indicando que praticamente qualquer dia com precipitação fica abaixo do patamar típico observado sob tempo aberto.

### 4.3 Ponto 3 – Relação entre Temperatura e total\_user por Grupo de Utilização

Na Questão 3, obteve-se  $r = 0,6376$  para a correlação global entre temperatura e utilização. Aqui, o diagrama de dispersão é refeito diferenciando os dias de baixa utilização ( $low\_usage = 1$ , em vermelho) dos demais ( $low\_usage = 0$ , em azul).

#### 4.3.1 Cálculo manual – 10 primeiras observações

Nas 10 primeiras observações (todas no inverno), o limiar adotado na Questão 2 foi  $Q_1 = 1876,75$ . Com isso, temos dois grupos:

- **Grupo  $low\_usage = 1$  ( $n = 3$ ):** composto pelos instantes 65 (15,4 °C; 605), 66 (10,7 °C; 1872) e 69 (16,0 °C; 623). As médias do grupo são  $\bar{x}_{low} = \frac{15,4+10,7+16,0}{3} = 14,0333$  °C e  $\bar{y}_{low} = \frac{605+1872+623}{3} = 1033,3333$  usuários.
- **Grupo  $low\_usage = 0$  ( $n = 7$ ):** composto pelos instantes 64, 67, 68, 70, 71, 72 e 73. As médias do grupo são  $\bar{x}_{norm} = \frac{95,5}{7} \approx 13,6429$  °C e  $\bar{y}_{norm} = \frac{14673}{7} \approx 2096,1429$  usuários.

A Tabela 15 apresenta o cálculo manual das somas de quadrados e produtos cruzados para cada um dos dois grupos.

**Tabela 15:** Cálculo auxiliar da correlação por grupo de uso – 10 primeiras observações

| Instant                                                                | $x_i$ | $y_i$ | $low\_usage$ | $(x_i - \bar{x}_{grupo})^2$ | $(y_i - \bar{y}_{grupo})^2$ | $(x_i - \bar{x}_{grupo})(y_i - \bar{y}_{grupo})$ |
|------------------------------------------------------------------------|-------|-------|--------------|-----------------------------|-----------------------------|--------------------------------------------------|
| <i>Grupo de Baixa Utilização (<math>low\_usage = 1, n = 3</math>)</i>  |       |       |              |                             |                             |                                                  |
| 65                                                                     | 15,4  | 605   | 1            | 1,8678                      | 183469,44                   | -585,39                                          |
| 66                                                                     | 10,7  | 1872  | 1            | 11,1111                     | 703361,78                   | -2795,56                                         |
| 69                                                                     | 16,0  | 623   | 1            | 3,8678                      | 168373,44                   | -806,99                                          |
| <b>Soma (<math>low\_usage = 1</math>)</b>                              |       |       |              | <b>16,8467</b>              | <b>1055204,67</b>           | <b>-4187,93</b>                                  |
| <i>Grupo de Utilização Normal (<math>low\_usage = 0, n = 7</math>)</i> |       |       |              |                             |                             |                                                  |
| 64                                                                     | 15,8  | 2077  | 0            | 4,6533                      | 366,45                      | -41,29                                           |
| 67                                                                     | 12,0  | 2133  | 0            | 2,6990                      | 1358,45                     | -60,55                                           |
| 68                                                                     | 12,1  | 1891  | 0            | 2,3804                      | 42083,59                    | 316,51                                           |
| 70                                                                     | 13,0  | 1977  | 0            | 0,4133                      | 14195,02                    | 76,59                                            |
| 71                                                                     | 13,5  | 2132  | 0            | 0,0204                      | 1285,73                     | -5,12                                            |
| 72                                                                     | 15,8  | 2417  | 0            | 4,6533                      | 102949,31                   | 692,13                                           |
| 73                                                                     | 13,3  | 2046  | 0            | 0,1176                      | 2514,31                     | 17,19                                            |
| <b>Soma (<math>low\_usage = 0</math>)</b>                              |       |       |              | <b>14,9371</b>              | <b>164752,86</b>            | <b>995,46</b>                                    |

A partir das somas parciais, obtêm-se os coeficientes de correlação:

$$r_{low\_f10} = \frac{-4187,93}{\sqrt{16,8467 \times 1055204,67}} = \frac{-4187,93}{\sqrt{17776774,01}} \approx \frac{-4187,93}{4216,25} \approx -0,9933$$

$$r_{norm\_f10} = \frac{995,46}{\sqrt{14,9371 \times 164752,86}} = \frac{995,46}{\sqrt{2460938,76}} \approx \frac{995,46}{1568,74} \approx 0,6346$$

Os valores calculados manualmente coincidem com os obtidos via código R (variáveis `cor_lowusage_f10` e `cor_normalusage_f10`):  $r_{low} = -0,9933$  e  $r_{norm} = 0,6346$ . O valor extremo de  $r = -0,9933$  no grupo de baixo uso decorre estritamente do tamanho amostral diminuto ( $n = 3$ ), no qual o único dia mais frio (10,7 °C) teve uso superior aos dois dias amenos (15,4 °C e 16,0 °C) que foram afetados por chuva ou domingo chuvoso. Já no grupo normal ( $n = 7$ ), a relação positiva moderada a forte ( $r = 0,6346$ ) se alinha à intuição física.

### 4.3.2 Resultados para as 300 observações do grupo

A Figura 14 apresenta a dispersão diferenciada entre temperatura e utilização para as 10 primeiras observações (Figura 14a) e para o conjunto completo de 300 observações (Figura 14b). A Tabela 16 sintetiza os parâmetros de cada grupo para a amostra integral.



**Figura 14:** Diagramas de dispersão entre temperatura e `total_user` por grupo de utilização

**Tabela 16:** Estatísticas e coeficientes de correlação por estrato de utilização – 300 observações

| Grupo de Uso                                     | <i>n</i>   | Temp. Média (°C) | Usuários Médios | Correlação ( <i>r</i> ) | <i>r</i> <sup>2</sup> |
|--------------------------------------------------|------------|------------------|-----------------|-------------------------|-----------------------|
| Baixa utilização ( <code>low_usage = 1</code> )  | 75         | 15,71            | 2147,24         | 0,1759                  | 0,0310                |
| Utilização normal ( <code>low_usage = 0</code> ) | 225        | 24,25            | 4366,92         | 0,4355                  | 0,1896                |
| <b>Conjunto Global (sem estratificação)</b>      | <b>300</b> | <b>22,11</b>     | <b>3812,00</b>  | <b>0,6376</b>           | <b>0,4065</b>         |

Três aspectos se destacam na comparação entre os grupos:

- Restrição de amplitude (*range restriction*):** As correlações intra-grupo ( $r = 0,1759$  na baixa utilização;  $r = 0,4355$  na normal) são menores que a correlação global ( $r = 0,6376$ ). Isso ocorre porque a estratificação por  $Q_1$  restringe a amplitude de `total_user` dentro de cada grupo, reduzindo a covariância e, consequentemente, o coeficiente  $r$ .
- Efeito entre-grupos:** O  $r$  global elevado reflete menos uma inclinação linear forte e mais a separação entre os dois grupos: dias de baixo uso concentram-se em temperaturas amenas ( $\bar{x} = 15,71$  °C;  $\bar{y} = 2147$ ), enquanto dias normais ocorrem em temperaturas mais altas ( $\bar{x} = 24,25$  °C;  $\bar{y} = 4367$ ). É essa distância entre grupos que infla o  $r$  agregado.
- Comportamento por grupo:** No grupo de baixa utilização (vermelho), a temperatura explica apenas  $r^2 = 3,1\%$  da variância — quando o dia já é de baixo uso por chuva ou frio intenso, a temperatura marginal não altera o comportamento. No grupo normal (azul), a relação é mais clara ( $r = 0,4355$ ), com uso crescente até a faixa de 28–32 °C, acima da qual o efeito se estabiliza.

#### 4.4 Ponto 4 – Conclusão Final

As 300 observações (05/03 a 29/12/2011) mostram que a demanda diária de bicicletas é determinada principalmente pela estação do ano e pela condição meteorológica. A série temporal revela um padrão sazonal claro: a demanda sobe da primavera ao verão, atinge o pico em julho (até 6043 usuários) e cai progressivamente até dezembro. O efeito sazonal é expressivo: a média de verão é 121,0% superior à de inverno (4464 vs. 2020 usuários/dia), com dias de baixo uso caindo de 92,0% para apenas 4,3%. A condição meteorológica tem impacto ainda mais severo: sob chuva fraca, a média cai 57,6% em relação ao céu limpo (1758 vs. 4150 usuários), e 100% desses dias foram de baixa utilização. A temperatura apresenta correlação global moderada ( $r = 0,6376$ ), mas esse valor é inflado pela separação entre os estratos: dentro de cada grupo, a correlação é sensivelmente menor ( $r = 0,44$  no uso normal e  $r = 0,18$  na baixa utilização), indicando que fatores adversos como chuva e frio pesam mais do que a oscilação térmica em si.

## Referências

- [1] **UNIVERSIDADE FEDERAL DO CEARÁ (UFC)**. *Slides das Aulas da Disciplina de Estatística para Engenharia (TI0111) – Aulas L01 a L04: Introdução à Estatística Descritiva, Medidas de Tendência Central, Dispersão, Separatrizes (Quartis e IQR), Gráficos (Boxplot e Histograma) e Associação Bivariada*. Fortaleza, 2026.
- [2] **FANAEE-T, H.; GAMA, J.** Event labeling combining ensemble detectors and background knowledge. *Progress in Artificial Intelligence*, Springer, v. 2, n. 2-3, p. 113–127, 2014.
- [3] **UCI MACHINE LEARNING REPOSITORY**. *Bike Sharing Dataset*. Capital Bikeshare System (Washington D.C.). Disponível em: <https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset>. Acesso em: set. 2026.
- [4] **R CORE TEAM**. *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria, 2024. Disponível em: <https://www.R-project.org/>.
- [5] **R DOCUMENTATION**. *The R Stats Package: Functions for Statistical Distributions and Calculations (quantile, cor, summary, sd)*. R Foundation for Statistical Computing, 2024.
- [6] **WICKHAM, H.; GROLEMUND, G.** *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. Sebastopol: O'Reilly Media, 2017.