



ESTATÍSTICA PARA ENGENHARIA

HOMEWORK 01

ANÁLISE DE COMPARTILHAMENTO DE BICICLETAS: UMA ABORDAGEM EM ESTATÍSTICA DESCRITIVA

ALUNOS:

ALEXANDRE DE AGUIAR MARTINS GRANGEIRO – 578345

BRUNO DELUIZ LAGE – 578342

DANNY SECUNDINO SOUSA FILHO – 579763

SAULO GOMES PINTO – 579493

1 Questão 1

A primeira questão tem o objetivo de definir o escopo de dados a serem utilizados pelo grupo ao longo de toda a análise. Para isso, foi feito um código R que fazia o que foi pedido no enunciado da questão. O código é este:

```
# =====  
# First Question  
# =====  
  
# 1. Defining the highest student number  
# students numbers  
alexandre_sn <- 578345  
bruno_sn <- 578342  
danny_sn <- 579763  
saulo_sn <- 579493  
  
# highest student number  
M <- max(c(alexandre_sn, bruno_sn, danny_sn, saulo_sn)) # 579763  
  
# 2. Defining the start and the end of group's dataset  
# start  
r <- 1 + (M %% 100)      # 64  
  
# end  
end <- 300 + r - 1      # 363  
  
# 3. Defining data_group (ie., the group's dataset)  
# loading the entire file  
all_data <- read.csv("HW1_bike_sharing.csv")  
  
# defining our scope  
data_group <- all_data[r:end, ]      # collect the lines 64-363  
  
# 4. Defining the first 10 observations (we'll use them in the subsequent questions to  
# validate our manual computations)  
first_ten <- data_group[1:10, ]
```

É importante analisar o que, de fato, foi implementado com esse código:

Primeiramente, foram definidas variáveis *_sn contendo, cada uma, o valor do número de matrícula de um dos quatro integrantes do grupo. Os valores dos números de matrículas são os seguintes:

- a) Alexandre Grangeiro: 578345;
- b) Bruno Lage: 578342;
- c) Danny Secundino: 579763;
- d) Saulo Gomes: 579493.

Após isso, a variável M foi declarada para guardar o maior número de matrícula dentre os números de matrícula dos membros do grupo. Dessa forma, obtém-se

$$M = 579763$$

Com a informação do maior número de matrícula, foi possível, então, definir o índice inicial do subconjunto de dados a ser analisado nesse trabalho. Tal informação ficou guardada na variável r e ele

foi calculado da seguinte maneira:

$$r = 1 + (M \bmod 100) = 1 + (579763 \bmod 100) = 1 + 63 \Rightarrow \boxed{r = 64}$$

Em que *mod* é a operação **resto de divisão**.¹

Com o índice de início do conjunto de dados a ser analisado e considerando que tal conjunto deveria ter 300 elementos, também foi definido o fim:

$$end = 300 + r - 1 = 300 + 64 - 1 \Rightarrow end = 363$$

Com o início e o fim da janela que define o escopo das análises, foi declarado o `data_group`, que pode ser usado ao longo de todo o código para fazer as outras questões. Também foi definido o `first_ten`, que contém as dez primeiras observações do conjunto de dados do grupo e que será especialmente útil para comparar os cálculos que serão feitos manualmente com os que serão obtidos com o código R.

Daí, foi possível coletar as datas da primeira e da última observação presentes em `data_group`. Elas foram:

- a) Data da primeira observação: 05/03/2011 (ou, no formato internacional, 2011-03-05)
- b) Data da última observação: 29/12/2011 (ou, no formato internacional, 2011-12-29)

Além disso, vale também apresentar as dez primeiras observações para que a análise ao longo do relatório seja melhor referenciada. Elas estão dispostas na tabela a seguir:

Tabela 1: Primeiras dez observações do conjunto `data_group`

Instant	Data	Estação	Clima	Temp.	Casual	Registrados	Total	Baixa Utiliz.
64	2011-03-05	1	2	15.8	640	1437	2077	0
65	2011-03-06	1	2	15.4	114	491	605	1
66	2011-03-07	1	1	10.7	244	1628	1872	1
67	2011-03-08	1	1	12.0	316	1817	2133	0
68	2011-03-09	1	2	12.1	191	1700	1891	0
69	2011-03-10	1	3	16.0	46	577	623	1
70	2011-03-11	1	2	13.0	247	1730	1977	0
71	2011-03-12	1	1	13.5	724	1408	2132	0
72	2011-03-13	1	1	15.8	982	1435	2417	0
73	2011-03-14	1	1	13.3	359	1687	2046	0

As variáveis `total_user` e `low_usage` também foram incluídas na tabela, de modo a consolidar em uma única tabela todos os dados que serão utilizados ao longo das análises seguintes.

Observação: Aqui, foram postas as datas da primeira e da última observações, mas essa informação também consta na saída do código fonte produzido. **Recomenda-se que se execute o código `main.r` para ver as informações que são fornecidas na saída.**

¹Em R, essa operação é realizada utilizando `%%`.

2 Questão 2

O objetivo desta seção é caracterizar o conjunto de dados específico do grupo (`data_group`), definido na Questão 1, calcular e interpretar as medidas de tendência central e os quartis das variáveis numéricas relevantes, identificar possíveis valores atípicos e definir a variável `low_usage`. As análises foram realizadas inicialmente de forma manual, com as dez primeiras observações do conjunto (`first_ten`), e, em seguida, verificadas e estendidas às 300 observações do grupo por meio do software R.

2.1 Ponto 1 – Caracterização das Variáveis

2.1.1 Classificação das variáveis

- `instant` – Numérica (discreta): índice sequencial que identifica cada registro; assume valores inteiros que apenas ordenam as observações, sem magnitude física associada.
- `dtoday` – Categórica (ordinal): representa a data da observação; ainda que expressa em formato numérico (ano-mês-dia), não é submetida a operações aritméticas, apenas ordena os registros no tempo.
- `season` – Categórica (nominal): codifica a estação do ano por meio de rótulos numéricos sem relação de ordem ou magnitude entre si.
- `weathersit` – Categórica (ordinal): codifica a condição meteorológica; os códigos seguem uma ordem crescente de severidade do tempo.
- `temp` – Numérica (contínua): representa a temperatura do dia, em graus Celsius; assume valores reais dentro de um intervalo contínuo.
- `casual` – Numérica (discreta): representa a contagem diária de usuários casuais; assume apenas valores inteiros não negativos.
- `registered` – Numérica (discreta): representa a contagem diária de usuários registrados; assume apenas valores inteiros não negativos.
- `total_user` – Numérica (discreta): variável derivada (`casual + registered`); representa o total diário de usuários do sistema.

2.1.2 Categorias das variáveis categóricas

- `season`: 1 – inverno, 2 – primavera, 3 – verão, 4 – outono (estações do ano no hemisfério norte).
- `weathersit`: 1 – céu limpo, 2 – nublado, 3 – chuva fraca, 4 – chuva forte (ordenadas por severidade da condição meteorológica).

Cabe observar que, no subconjunto de 300 observações do grupo (`data_group`), não há nenhum dia classificado com `weathersit = 4` (chuva forte), de modo que essa categoria, embora definida, não é representada na amostra analisada.

2.1.3 Unidades e significado das variáveis numéricas

- `instant`: sem unidade de medida; identificador sequencial do registro.
- `temp`: graus Celsius; representa a temperatura observada no dia.

- `casual`: pessoas/dia; representa a quantidade de usuários que utilizaram o sistema sem vínculo de cadastro.
- `registered`: pessoas/dia; representa a quantidade de usuários cadastrados que utilizaram o sistema no mesmo dia.
- `total_user`: pessoas/dia; variável derivada que soma `casual` e `registered`, representando o total de usuários do sistema em cada dia observado.

2.1.4 Valores ausentes

A verificação de valores ausentes foi feita por meio da função `is.na()` aplicada a `data_group` (variável `has_missing_values` no código). O resultado obtido foi `FALSE`, isto é, não há valores ausentes em nenhuma das variáveis do conjunto de 300 observações do grupo.

2.2 Ponto 2 – Medidas de Tendência Central

As medidas de tendência central foram calculadas para as variáveis numéricas relevantes (`temp`, `casual`, `registered` e `total_user`): média, mediana e, quando aplicável, moda.

A média aritmética $\bar{x}$ é dada por

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

A mediana Me corresponde ao valor central do conjunto ordenado (ou à média dos dois valores centrais, quando n é par):

$$Me = \frac{x_{(n/2)} + x_{(n/2+1)}}{2}, \quad \text{para } n \text{ par}$$

Para o cálculo manual, considera-se

$$n = 10$$

2.2.1 Cálculo manual – 10 primeiras observações

A Tabela 2 apresenta os valores de cada variável ordenados de forma crescente, com os dois valores centrais (posições 5 e 6, usados no cálculo da mediana) destacados em negrito.

Tabela 2: Valores ordenados (crescente) – 10 primeiras observações

Posição	temp (°C)	casual	registered	total_user
1	10,7	46	491	605
2	12,0	114	577	623
3	12,1	191	1408	1872
4	13,0	244	1435	1891
5	13,3	247	1437	1977
6	13,5	316	1628	2046
7	15,4	359	1687	2077
8	15,8	640	1700	2132
9	15,8	724	1730	2133
10	16,0	982	1817	2417

temp

$$\begin{aligned}\bar{x} &= (10,7 + 12,0 + 12,1 + 13,0 + 13,3 \\ &\quad + 13,5 + 15,4 + 15,8 + 15,8 + 16,0) / 10 \\ &= 137,6 / 10 = 13,76 \text{ °C}\end{aligned}$$

$$Me = \frac{13,3 + 13,5}{2} = 13,40 \text{ °C}$$

casual

$$\begin{aligned}\bar{x} &= (46 + 114 + 191 + 244 + 247 \\ &\quad + 316 + 359 + 640 + 724 + 982) / 10 \\ &= 3863 / 10 = 386,30\end{aligned}$$

$$Me = \frac{247 + 316}{2} = 281,50$$

registered

$$\begin{aligned}\bar{x} &= (491 + 577 + 1408 + 1435 + 1437 \\ &\quad + 1628 + 1687 + 1700 + 1730 + 1817) / 10 \\ &= 13910 / 10 = 1391,00\end{aligned}$$

$$Me = \frac{1437 + 1628}{2} = 1532,50$$

total_user

$$\begin{aligned}\bar{x} &= (605 + 623 + 1872 + 1891 + 1977 \\ &\quad + 2046 + 2077 + 2132 + 2133 + 2417) / 10 \\ &= 17773 / 10 = 1777,30\end{aligned}$$

$$Me = \frac{1977 + 2046}{2} = 2011,50$$

Os valores calculados manualmente coincidem com os obtidos por meio do código R (variáveis `xn_first10_*` e `me_first10_*`), conforme resumido na Tabela 3:

Tabela 3: Medidas de tendência central – 10 primeiras observações

Variável	Média	Mediana	Moda
temp	13,76 °C	13,40 °C	–
casual	386,30	281,50	–
registered	1391,00	1532,50	–
total_user	1777,30	2011,50	–

Os mesmos cálculos foram estendidos às 300 observações do grupo (variáveis `xn_*` e `me_*`):

Para nenhuma das quatro variáveis numéricas há um valor que se repita com frequência relevante, de modo que a moda não constitui uma medida significativa nesse conjunto de dados, tanto nas 10 primeiras observações quanto nas 300 observações do grupo.

Tabela 4: Medidas de tendência central – 300 observações do grupo

Variável	Média	Mediana	Moda
temp	22,11 °C	22,20 °C	–
casual	786,92	691,50	–
registered	3025,08	3238,50	–
total_user	3812,00	4067,50	–

Nas 300 observações, observa-se que a média de `casual` (786,92) é superior à sua mediana (691,50), indicando uma distribuição assimétrica à direita: a maioria dos dias apresenta uso casual moderado, enquanto um número menor de dias com uso muito elevado eleva o valor da média. Padrão semelhante, embora menos acentuado, é observado nas 10 primeiras observações. Já para `registered` e `total_user`, a média é ligeiramente inferior à mediana, sugerindo leve assimetria à esquerda, compatível com a existência de alguns dias de uso registrado bastante baixo (possivelmente fins de semana ou feriados) que reduzem o valor médio. A variável `temp` apresenta média e mediana muito próximas nas 300 observações (22,11 °C e 22,20 °C), o que é coerente com o período coberto pela amostra do grupo, que se estende de março a dezembro de 2011, abrangendo estações de temperatura variada e resultando em uma distribuição aproximadamente simétrica.

2.3 Ponto 3 – Quartis e Valores Atípicos

A variável escolhida para a análise de quartis e valores atípicos foi `casual` (número de usuários casuais por dia). A escolha se justifica por essa variável representar o quantitativo de usuários que utilizam o sistema de forma espontânea, sem vínculo de registro (`registered`). Por não estarem associados a um cadastro fixo, esses usuários refletem de maneira mais direta a demanda ocasional pelo serviço, tornando essa variável adequada para identificar dias com comportamento de uso atípico em relação ao padrão observado.

Os quartis Q_1 , Q_2 e Q_3 dividem o conjunto ordenado de dados em quatro partes de igual tamanho. O intervalo interquartil é dado por

$$IQR = Q_3 - Q_1$$

Os limites inferior e superior para identificação de possíveis valores atípicos, segundo o critério do IQR, são dados por

$$LI = Q_1 - 1,5 \cdot IQR \quad LS = Q_3 + 1,5 \cdot IQR$$

2.3.1 Cálculo manual dos quartis – 10 primeiras observações

Para o cálculo manual, com $N = 10$, a posição de cada quartil no conjunto ordenado é obtida por

$$\text{posição}(Q_1) = \frac{N+1}{4} = \frac{11}{4} = 2,75$$

$$\text{posição}(Q_2) = \frac{N+1}{2} = \frac{11}{2} = 5,50$$

$$\text{posição}(Q_3) = \frac{3(N+1)}{4} = \frac{33}{4} = 8,25$$

Com os valores de `casual` já ordenados na Tabela 2 (46, 114, 191, 244, 247, 316, 359, 640, 724,

982), cada quartil é obtido por interpolação linear entre as posições inteiras adjacentes:

$$Q_1 = 114 + 0,75 \cdot (191 - 114) = 171,75$$

$$Q_2 = 247 + 0,5 \cdot (316 - 247) = 281,50$$

$$Q_3 = 640 + 0,25 \cdot (724 - 640) = 661,00$$

$$IQR = Q_3 - Q_1 = 661,00 - 171,75 = 489,25$$

$$LI = 171,75 - 1,5 \cdot 489,25 = -562,125 \quad LS = 661,00 + 1,5 \cdot 489,25 = 1394,875$$

Como todos os valores de `casual` nas 10 primeiras observações estão contidos no intervalo $[-562,125; 1394,875]$, nenhuma observação é classificada como atípica também pelo cálculo manual, resultado consistente com o obtido via R.

Para as 10 primeiras observações (variáveis `Q1_f10`, `Q2_f10`, `Q3_f10`, `iqr_f10`, `lower_bound_f10`, `upper_bound_f10` e `outliers_f10` no código):

Tabela 5: Quartis e limites de valores atípicos de `casual` – 10 primeiras observações

Q_1	204,25
Q_2	281,50
Q_3	569,75
IQR	365,50
Limite inferior	-344,00
Limite superior	1118,00

Observa-se que os valores de Q_1 e Q_3 calculados manualmente (171,75 e 661,00) diferem dos valores obtidos pela função `quantile()` do R (204,25 e 569,75). Essa diferença decorre da convenção de interpolação adotada por cada método: o cálculo manual utiliza a posição $\frac{N+1}{4}$ (equivalente ao tipo 6 de quantil), enquanto a função `quantile()` do R utiliza, por padrão, a posição $1 + (n - 1) \cdot p$ (tipo 7). Já a mediana ($Q_2 = 281,50$) coincide exatamente entre os dois métodos, pois ambas as convenções resultam na mesma posição central ($\frac{N+1}{2} = 5,5$) para esse caso. Em ambos os métodos, entretanto, a conclusão quanto à ausência de valores atípicos nas 10 primeiras observações se mantém.

O mesmo procedimento (via R) foi aplicado às 300 observações do grupo (variáveis `Q1`, `Q2`, `Q3`, `iqr`, `lower_bound`, `upper_bound` e `outliers`):

Tabela 6: Quartis e limites de valores atípicos de `casual` – 300 observações do grupo

Q_1	376,75
Q_2	691,50
Q_3	949,75
IQR	573,00
Limite inferior	-482,75
Limite superior	1809,25

Nas 10 primeiras observações, nenhum dia foi classificado como valor atípico: todos os valores de `casual` nesse subconjunto encontram-se dentro do intervalo $[-344,00; 1118,00]$. Já nas 300 observações do grupo, foram identificados 18 dias com valor de `casual` acima do limite superior (1809,25) – não houve valores abaixo do limite inferior, o que é esperado, já que esse limite é negativo e `casual` não assume valores negativos. As datas classificadas como atípicas estão listadas na Tabela 7.

Observa-se que todas as datas atípicas se concentram entre final de abril e meados de outubro,


Tabela 7: Dias classificados como valores atípicos de `casual` – 300 observações do grupo

Data	<code>casual</code>	Data	<code>casual</code>
30/04/2011	1965	09/07/2011	1988
21/05/2011	2258	16/07/2011	2418
28/05/2011	2001	17/07/2011	2006
29/05/2011	2355	20/08/2011	1914
04/06/2011	1869	03/09/2011	1935
26/06/2011	1920	04/09/2011	2521
02/07/2011	2204	08/10/2011	2235
03/07/2011	2282	09/10/2011	2397
04/07/2011	3065	15/10/2011	1899


período de clima mais ameno no hemisfério norte, e incluem finais de semana e datas próximas a feriados (como 04/07/2011, Dia da Independência dos EUA, e o final de semana de 28–29/05/2011, próximo ao feriado de Memorial Day). Esse padrão é coerente com a natureza da variável `casual`: por não exigir cadastro, o uso casual do sistema tende a ser mais sensível a condições favoráveis de lazer (bom tempo, folgas e feriados), o que explica a ocorrência de picos pontuais de demanda muito acima do padrão típico. Esses valores atípicos são relevantes para a análise do sistema por sinalizarem dias de pico de demanda que podem exigir redistribuição adicional de bicicletas ou reforço operacional.

2.4 Ponto 4 – Histograma e Boxplot

Para a variável `casual`, foram construídos histogramas e boxplots, tanto para as 10 primeiras observações quanto para as 300 observações do grupo, permitindo analisar forma, dispersão, assimetria e a presença de valores atípicos.


Figura 1: Distribuição de `casual` – 10 primeiras observações

Nas 10 primeiras observações, os valores de `casual` variam de 46 a 982 usuários por dia. O histograma exibe uma distribuição irregular, esperada dado o tamanho reduzido da amostra, com leve concentração nos valores mais baixos e uma cauda à direita. O boxplot correspondente não apresenta pontos além dos limites dos whiskers, em concordância com a ausência de valores atípicos apontada no Ponto 3, mas já evidencia uma mediana deslocada para a parte inferior da caixa, um primeiro indício de assimetria à direita.



(a) Histograma – 300 observações do grupo

(b) Boxplot – 300 observações do grupo

Figura 2: Distribuição de `casual` – 300 observações do grupo

Nas 300 observações do grupo, o histograma revela uma distribuição unimodal com assimetria positiva (à direita) bem mais evidente: a maior parte dos dias concentra-se na faixa entre aproximadamente 200 e 950 usuários casuais (intervalo entre Q_1 e Q_3), com uma cauda longa se estendendo até o valor máximo de 3065. O boxplot confirma esse padrão – a mediana está deslocada para a parte inferior da caixa, o whisker superior é bem mais longo que o inferior, e os 18 valores atípicos aparecem representados como pontos isolados acima do limite superior. De forma geral, o histograma evidencia melhor a forma global da distribuição (concentração, cauda e multimodalidade, caso existisse), enquanto o boxplot evidencia de forma mais direta e quantitativa os quartis, a mediana e a posição exata dos valores atípicos.

2.5 Ponto 5 – Variável `low_usage`

Com base no primeiro quartil Q_1 de `total_user`, foi definida a variável binária `low_usage`, segundo o critério

$$\text{low_usage} = \begin{cases} 1, & \text{se } \text{total_user} < Q_1 \\ 0, & \text{caso contrário} \end{cases}$$

Diferentemente da escolha de `casual` feita no Ponto 3 – em que a variável foi selecionada pelo grupo entre as opções relevantes –, aqui a variável de referência é `total_user` porque o próprio critério de definição de `low_usage`, apresentado no enunciado, utiliza explicitamente o primeiro quartil dessa variável como limiar (Equação anterior).

2.5.1 Cálculo manual de Q_1 – 10 primeiras observações

Assim como no Ponto 3, a posição do primeiro quartil no conjunto ordenado é obtida por

$$\text{posição}(Q_1) = \frac{N+1}{4} = \frac{11}{4} = 2,75, \quad N = 10$$

Com os valores de `total_user` já ordenados na Tabela 2 (605, 623, 1872, 1891, 1977, 2046, 2077,

2132, 2133, 2417), o quartil é obtido por interpolação linear entre a 2ª e a 3ª posições:

$$Q_1 = 623 + 0,75 \cdot (1872 - 623) = 1559,75$$

Esse valor difere do obtido pela função `quantile()` do R ($Q_1 = 1876,75$) pela mesma razão discutida no Ponto 3: a convenção de interpolação da posição $\frac{N+1}{4}$ (tipo 6) diverge da convenção padrão do R, $1 + (n - 1) \cdot p$ (tipo 7). Usando o valor manual (1559,75), apenas 2 das 10 primeiras observações seriam classificadas como `low_usage` (20%), contra as 3 observações (30%) obtidas com o valor verificado em R. Os resultados apresentados a seguir seguem o valor calculado via R, em consonância com a metodologia adotada no restante do relatório.

Para as 10 primeiras observações, o valor de referência foi $Q_1 = 1876,75$ (variável `Q1_lowusage_f10`), resultando em 3 dias classificados como de baixa utilização, correspondendo a uma proporção de 30% (variável `prop_lu_f10`).

Para as 300 observações do grupo, o valor de referência foi $Q_1 = 3116,50$ (variável `Q1_lowusage`), resultando em 75 dias classificados como de baixa utilização, correspondendo a uma proporção de 25% (variável `prop_lu`).

Por construção, a proporção de dias classificados como `low_usage` tende a se aproximar de 25%, já que o critério utiliza exatamente o primeiro quartil da própria distribuição de `total_user` – o que é confirmado pelo resultado obtido nas 300 observações do grupo. Na amostra reduzida de 10 observações, a proporção observada (30%) se afasta ligeiramente desse valor teórico em razão do tamanho pequeno da amostra, que torna a posição exata do quartil mais sensível a poucos valores e a possíveis empates. No contexto do sistema, os dias marcados como `low_usage` correspondem tipicamente a condições que desestimulam o uso das bicicletas – como baixas temperaturas, condições meteorológicas desfavoráveis ou dias da semana com menor mobilidade –, constituindo uma variável útil para segmentar e investigar os fatores associados à baixa demanda do sistema.

3 Questão 3

O objetivo desta seção é investigar as características associadas aos dias de menor utilização do sistema, a partir da variável `low_usage` definida na Questão 2. Assim como nas seções anteriores, os cálculos foram feitos manualmente com as dez primeiras observações (`first_ten`) e verificados e estendidos às 300 observações do grupo (`data_group`) por meio do R. Para as 300 observações, o limiar de baixa utilização é $Q_1 = 3116,50$ (variável `Q1_lowusage`); para as 10 primeiras, $Q_1 = 1876,75$ (variável `Q1_lowusage_f10`), ambos referentes a `total_user`. O desvio padrão calculado é o amostral (denominador $n - 1$), o mesmo da função `sd()` do R.

3.1 Ponto 1 – Utilização por Estação do Ano

Para cada estação foram calculados a média, a mediana e o desvio padrão de `total_user`, além da proporção de dias classificados como `low_usage`.

3.1.1 Cálculo manual – 10 primeiras observações

As 10 primeiras observações (05/03/2011 a 14/03/2011) pertencem todas à estação 1 (inverno). Portanto, as demais estações não possuem observações nesse subconjunto e suas medidas são indefinidas. A Tabela 8 apresenta os dados, com `low_usage` calculado com $Q_1 = 1876,75$.

Tabela 8: Total de usuários e indicador de baixo uso – 10 primeiras observações de inverno

Instant	Data	Estação	casual	registered	total_user	low_usage
64	2011-03-05	1	640	1437	2077	0
65	2011-03-06	1	114	491	605	1
66	2011-03-07	1	244	1628	1872	1
67	2011-03-08	1	316	1817	2133	0
68	2011-03-09	1	191	1700	1891	0
69	2011-03-10	1	46	577	623	1
70	2011-03-11	1	247	1730	1977	0
71	2011-03-12	1	724	1408	2132	0
72	2011-03-13	1	982	1435	2417	0
73	2011-03-14	1	359	1687	2046	0

Média

$$\bar{x} = \frac{2077 + 605 + 1872 + 2133 + 1891 + 623 + 1977 + 2132 + 2417 + 2046}{10} = \frac{17773}{10} = 1777,30$$

Mediana Com os valores ordenados (605, 623, 1872, 1891, 1977, 2046, 2077, 2132, 2133, 2417) e $n = 10$ par,

$$Me = \frac{x_{(5)} + x_{(6)}}{2} = \frac{1977 + 2046}{2} = 2011,50$$

Desvio padrão amostral

$$\sum_{i=1}^{10} (x_i - \bar{x})^2 = 89820,09 + 1374287,29 + 8968,09 + 126522,49 + 12927,69 \\ + 1332409,49 + 39880,09 + 125811,09 + 409216,09 + 72199,69 = 3592042,10$$

$$s = \sqrt{\frac{3592042,10}{10 - 1}} = \sqrt{399115,79} \approx 631,76$$

Proporção de low_usage Os instants 65, 66 e 69 têm `total_user` < 1876,75:

$$p = \frac{0 + 1 + 1 + 0 + 0 + 1 + 0 + 0 + 0 + 0}{10} = \frac{3}{10} = 0,30$$


Os valores calculados manualmente coincidem com os obtidos por meio do código R (variáveis `xn_winter_f10`, `me_winter_f10`, `sd_winter_f10` e `prop_lu_winter_f10`): média 1777,30, mediana 2011,50, $s = 631,7561$ e proporção 0,3. Para primavera, verão e outono, as variáveis correspondentes resultam em NaN/NA, e o código evita o boxplot desses grupos vazios.

3.1.2 Resultados para as 300 observações do grupo

O mesmo procedimento foi aplicado às 300 observações (variáveis `xn_*`, `me_*`, `sd_*` e `prop_lu_*` de cada estação). O inverno tem 25 dias no recorte do grupo (16 dias de março e 9 de dezembro); primavera, verão e outono têm 92, 94 e 89 dias, respectivamente.

Tabela 9: Utilização do sistema por estação – 300 observações do grupo

Estação	<i>n</i>	Média	Mediana	Desv. padrão	Prop. low_usage
Inverno	25	2019,92	2132,00	743,46	0,9200
Primavera	92	3775,17	4085,50	1138,90	0,2609
Verão	94	4464,36	4615,50	798,35	0,0426
Outono	89	3664,46	3717,00	983,01	0,2697


Figura 3: Boxplot de `total_user` – 10 primeiras observações (inverno)




Figura 4: Boxplot de `total_user` por estação – 300 observações do grupo

O verão apresenta a maior média (4464,36) e a maior mediana (4615,50), com apenas 4,26% de dias de baixa utilização, e é a estação de menor dispersão em torno da média (desvio padrão de 798,35). O inverno é o oposto: menor média (2019,92) e 92% dos dias abaixo do limiar $Q_1 = 3116,50$ (23 dos 25 dias), ou seja, quase todo dia de inverno é de baixa utilização. Primavera e outono ficam em posição intermediária, com proporções de `low_usage` próximas de 26–27%, valores parecidos com os 25% esperados para o conjunto todo. A primavera tem o maior desvio padrão (1138,90), possivelmente dado que está entre o inverno (de menor uso) e o verão (de maior uso). Em todas as estações a média é inferior à mediana, o que sugere leve assimetria à esquerda, provocada por dias isolados de uso muito baixo. O inverno tem apenas 25 dias no recorte do grupo, de modo que suas medidas são menos estáveis que as das demais estações.

3.2 Ponto 2 – Utilização por Condição Meteorológica

Para cada condição (1 – céu limpo, 2 – nublado, 3 – chuva fraca, 4 – chuva forte), foram calculados a média e o desvio padrão de `total_user` e a proporção de dias de `low_usage`. O código calcula também a mediana, que foi incluída na análise das 300 observações.

3.2.1 Cálculo manual – 10 primeiras observações

Nas 10 primeiras observações, há 5 dias de céu limpo (instants 66, 67, 71, 72 e 73), 4 nublados (64, 65, 68 e 70), 1 de chuva fraca (69) e nenhum de chuva forte.

Céu limpo ($n = 5$; valores 1872, 2133, 2132, 2417, 2046):

$$\bar{x} = \frac{10600}{5} = 2120,00$$

$$\sum (x_i - \bar{x})^2 = 61504 + 169 + 144 + 88209 + 5476 = 155502 \quad s = \sqrt{\frac{155502}{4}} = \sqrt{38875,5} \approx 197,17$$

$$p = \frac{1}{5} = 0,20 \quad (\text{apenas o instant 66, com } 1872 < 1876,75)$$

Nublado ($n = 4$; valores 2077, 605, 1891, 1977):

$$\bar{x} = \frac{6550}{4} = 1637,50$$

$$\sum (x_i - \bar{x})^2 = 193160,25 + 1066056,25 + 64262,25 + 115260,25 = 1438739 \quad s = \sqrt{\frac{1438739}{3}} \approx 692,52$$

$$p = \frac{1}{4} = 0,25 \quad (\text{apenas o instant 65, com } 605 < 1876,75)$$

Chuva fraca ($n = 1$; valor 623): $\bar{x} = 623,00$ e $p = 1,00$. Com $n = 1$, o desvio padrão amostral é indefinido, pois o denominador $n - 1$ é nulo (NA no R).

Chuva forte ($n = 0$): não há observações, logo média, desvio padrão e proporção são indefinidos.

Tabela 10: Utilização por condição meteorológica – 10 primeiras observações

Condição	n	Média	Desv. padrão	Prop. <code>low_usage</code>
Céu limpo	5	2120,00	197,17	0,20
Nublado	4	1637,50	692,52	0,25
Chuva fraca	1	623,00	–	1,00
Chuva forte	0	–	–	–




Figura 5: Boxplot de `total_user` por condição meteorológica – 10 primeiras observações

Os valores coincidem com os do código R (variáveis `xn*_f10`, `sd*_f10` e `prop_lu*_f10` de cada condição). Com grupos de tamanhos 5, 4 e 1, não há valores suficientes para fazer comparações sem distorções.

3.2.2 Resultados para as 300 observações do grupo

Nas 300 observações, há 185 dias de céu limpo, 101 nublados e 14 de chuva fraca. Não há nenhum dia de chuva forte (`weathersit = 4`), como já observado no Ponto 1 da Questão 2, e por isso essa condição não pode ser analisada.

Tabela 11: Utilização por condição meteorológica – 300 observações do grupo

Condição	<i>n</i>	Média	Mediana	Desv. padrão	Dias low_usage	Proporção
Céu limpo	185	4149,83	4381,00	990,24	26	0,1405
Nublado	101	3477,98	3740,00	1085,68	35	0,3465
Chuva fraca	14	1757,57	1829,50	793,95	14	1,0000
Chuva forte	0	–	–	–	–	–




Figura 6: Boxplot de `total_user` por condição meteorológica – 300 observações do grupo




Figura 7: Proporção de dias de baixa utilização por condição meteorológica

A média de `total_user` cai à medida que a condição meteorológica piora: 4149,83 (céu limpo), 3477,98 (nublado) e 1757,57 (chuva fraca), com medianas na mesma ordem. Em chuva fraca, a média é menos da metade da observada em dias de céu limpo. A proporção de `low_usage` reforça o padrão: 14,05% em dias de céu limpo, 34,65% em dias nublados e 100% em dias de chuva fraca, isto é, todos os 14 dias de chuva fraca estão abaixo do limiar $Q_1 = 3116,50$. Os desvios padrão são de magnitude semelhante (entre 794 e 1086), com a maior variabilidade nos dias nublados. Como o grupo de chuva fraca tem apenas 14 dias e não há dias de chuva forte, as conclusões sobre condições adversas devem ser tomadas com cautela.

3.3 Ponto 3 – Relação entre Temperatura e `total_user`

A associação linear entre a temperatura (x , em °C) e `total_user` (y) foi medida pelo coeficiente de correlação:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

3.3.1 Cálculo manual – 10 primeiras observações


Com $\bar{x} = 13,76$ e $\bar{y} = 1777,30$, obtém-se a Tabela 12.

$$r = \frac{-4063,98}{\sqrt{32,104 \times 3592042,10}} = \frac{-4063,98}{\sqrt{115318919,6}} \approx \frac{-4063,98}{10738,67} \approx -0,3784$$

Esse valor coincide com o obtido no código R (variável `temp_tu_cor_f10 = -0,3784437`). Nas 10 primeiras observações, a associação é moderada e de sinal negativo, contrariando a expectativa de que dias mais quentes tenham mais usuários. Isso pode muito bem decorrer do tamanho reduzido da amostra: os dois menores valores de `total_user` (605 e 623) ocorrem em dias de temperatura relativamente alta para o subconjunto (15,4 °C e 16,0 °C), sendo o segundo um dia de chuva fraca. Nesse subconjunto, outros fatores que não a temperatura dominam a variação do uso.

Tabela 12: Cálculo auxiliar da correlação – 10 primeiras observações

Instant	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})^2$	$(y_i - \bar{y})^2$	$(x_i - \bar{x})(y_i - \bar{y})$
64	15,8	2077	2,04	299,7	4,1616	89820,09	611,388
65	15,4	605	1,64	-1172,3	2,6896	1374287,29	-1922,572
66	10,7	1872	-3,06	94,7	9,3636	8968,09	-289,782
67	12,0	2133	-1,76	355,7	3,0976	126522,49	-626,032
68	12,1	1891	-1,66	113,7	2,7556	12927,69	-188,742
69	16,0	623	2,24	-1154,3	5,0176	1332409,49	-2585,632
70	13,0	1977	-0,76	199,7	0,5776	39880,09	-151,772
71	13,5	2132	-0,26	354,7	0,0676	125811,09	-92,222
72	15,8	2417	2,04	639,7	4,1616	409216,09	1304,988
73	13,3	2046	-0,46	268,7	0,2116	72199,69	-123,602
Soma					32,104	3592042,10	-4063,980


Figura 8: Diagrama de dispersão entre `temp` e `total_user` – 10 primeiras observações

3.3.2 Resultados para as 300 observações do grupo

Para as 300 observações, temos do código (variável `temp_tu_cor`)

$$r = 0,6376 \quad r^2 \approx 0,4065$$




Figura 9: Diagrama de dispersão entre temp e total_user – 300 observações do grupo

O coeficiente $r = 0,6376$ indica uma associação positiva e de intensidade moderada a forte: dias mais quentes tendem a apresentar maior número total de usuários. O coeficiente de determinação, $r^2 \approx 0,41$, indica que cerca de 41% da variação de total_user é explicada linearmente pela temperatura, restando aproximadamente 59% associado a outros fatores.

No entanto, o coeficiente de correlação possui algumas limitações. Vale notar que a temperatura está fortemente associada à estação do ano e às condições meteorológicas, que também afetam o uso do sistema. Parte da correlação pode refletir esses fatores em vez de ser um efeito direto da temperatura e, então, não haveria causalidade. Além disso, o coeficiente mede apenas relações lineares entre os dados. Caso a associação entre usuários e temperatura seja curva, com alguma saturação em temperaturas mais altas, o coeficiente de correlação não consegue representar muito bem essa dinâmica, dada sua natureza linear.

3.4 Ponto 4 – Características Mais Associadas à Utilização do Sistema

Com base nos resultados dos Pontos 1, 2 e 3, as duas características que parecem estar mais fortemente associadas à utilização do sistema são a estação do ano e a condição meteorológica.

A Tabela 9 mostra a maior amplitude entre grupos dentre todas as características analisadas: a média de total_user varia de 2019,92 (inverno) a 4464,36 (verão), uma diferença de mais de 2400 usuários por dia. Ademais, a proporção de dias de baixa utilização varia de 4,26% no verão a 92,00% no inverno. Essa diferença de quase 88 pontos percentuais entre os extremos é extremamente expressiva e, portanto, um fortíssimo indício de que a estação do ano é o fator isolado mais discriminante entre dias de alta e baixa utilização do sistema.

Já a Tabela 11 mostra outro padrão observável: a média de `total_user` cai de 4149,83 (céu limpo) para 1757,57 (chuva fraca), e a proporção de dias de `low_usage` sobe de 14,05% para 100,00%. Em outras palavras, todos os 14 dias de chuva fraca do grupo são classificados como de baixa utilização. Esse resultado permite inferir que a condição climática interfere quase deterministicamente na taxa de utilização do sistema.

Quanto à temperatura, é possível dizer que apresenta associação relevante com `total_user` ($r = 0,6376$ nas 300 observações), mas essa correlação é de intensidade moderada e explica apenas cerca de 41% da variância de `total_user` ($r^2 \approx 0,41$), contra os efeitos muito mais acentuados observados por estação e por condição meteorológica. Além disso, a temperatura está intimamente correlacionada com a própria estação do ano e com a condição meteorológica (dias quentes tendem a ser dias de verão e de céu limpo), de modo que parte do efeito atribuído à temperatura é, em boa medida, um reflexo desses dois outros fatores, e não um efeito independente.

Assim, estação do ano e condição meteorológica se destacam como as características mais associadas à utilização do sistema dada a proporção de dias classificados como `low_usage`, que nos dois casos varia de valores muito baixos (4,26% no verão; 14,05% em dias de céu limpo) a valores extremos (92,00% no inverno; 100,00% em dias de chuva fraca).

4 Questão 4