



HOMEWORK 1

O objetivo do primeiro *homework* é revisar e se familiarizar com os conceitos de estatística descritiva. Você pode consultar os slides das aulas (de L01 a L04) para os conceitos teóricos e exemplos de código em R [The objective of the first homework is to revise and familiarise with the concepts of descriptive statistics. You may refer to the lecture slides (from L01 to L04) for the theoretical background and R code examples].

O trabalho deverá ser realizado em grupos de 3 A 4 ESTUDANTES, com uma única solução por grupo e a identificação de todos os integrantes. As questões foram organizadas de forma encadeada. O conjunto de dados construído na Questão 1 deverá ser utilizado nas questões seguintes, e os resultados de uma questão serão utilizados nas posteriores [The homework must be completed in groups of 3 TO 4 STUDENTS, with one submission per group and the identification of all group members. The questions are organised sequentially. The dataset constructed in Question 1 must be used in all subsequent questions, and the results obtained in one question will be used in later questions].

INSTRUÇÕES: O grupo deve entregar o seguintes [The group must submit the following]:

- RELATÓRIO: Resolva cada exercício utilizando cálculos teóricos e descreva, de forma clara, as principais etapas do seu raciocínio. Em seguida, compare os resultados obtidos com aqueles gerados utilizando a linguagem R. Os pontos estão distribuídos igualmente entre as questões [Solve each exercise using theoretical calculations, and clearly describe the main steps of your reasoning. Then, compare your results with those obtained using the R programming environment. Points are equally distributed among the questions].
- O relatório deve seguir uma estrutura lógica e bem organizada, garantindo clareza e facilitando a avaliação. Para cada exercício, inclua um parágrafo introdutório curto, apresentando brevemente o objetivo geral da tarefa e uma descrição do conjunto de dados utilizado. Descreva as ferramentas, pacotes e métodos estatísticos aplicados. Explique a resolução da questão, com os cálculos relevantes, gráficos (quando aplicável), tabelas e, principalmente, as interpretações [The report should follow a logical and well-organized structure to ensure clarity and ease of evaluation. For each exercise, include a short introductory paragraph briefly presenting the general objective of the task and a description of the dataset used. Describe the tools, packages, and statistical methods applied. Discuss the solution to the question, including relevant calculations, graphs (when applicable), tables, and especially interpretations].
- Foque em clareza e concisão. Não inclua saídas brutas do R sem explicação, sempre interprete os resultados apresentados. Utilize gráficos e tabelas de forma eficiente,

garantindo que cada elemento visual tenha título, legenda e seja pertinente à análise. Evite informações redundantes e mantenha uma formatação limpa e consistente ao longo do documento [Focus on clarity and conciseness. Do not include raw R output without explanation, always interpret the results. Use graphs and tables efficiently, ensuring each visual element has a title, legend, and is relevant to the analysis. Avoid redundancy and keep formatting clean and consistent throughout the document].

- Utilize uma linguagem técnica, objetiva e impessoal. Evite expressões como “eu acho” ou “nós acreditamos”. Prefira construções como “os resultados indicam que...” ou “observou-se que...”. Estruture bem os parágrafos, organize o conteúdo por seções e identifique claramente as respostas para cada item da atividade [Use a technical, objective, and impersonal tone. Avoid expressions like “I think” or “we believe”. Prefer formulations such as “the results indicate that...” or “it was observed that...”. Structure your paragraphs well, organize the content into sections, and clearly identify the answers to each item of the assignment].
- LISTAGEM DE CÓDIGO: Envie o código utilizado para realizar a análise. O código deve ser funcional e executável, com todos os pacotes e dependências devidamente especificados. Ele pode ser incluído ao final do relatório como apêndice ou enviado separadamente em um arquivo compactado (.zip) [Submit the code used to perform the analysis. The code must be functional and executable, with all packages and dependencies clearly specified. It may be included at the end of the report as an appendix or submitted separately in a compressed file (.zip)].
- REPOSITÓRIO: Crie e compartilhe com a professora um repositório Git (por exemplo, no [GitHub](#))¹, de forma que seja possível acompanhar o desenvolvimento do projeto ao longo do tempo. O repositório deve conter: (i) o relatório final em PDF, (ii) todo o código-fonte utilizado na análise, (iii) quaisquer arquivos auxiliares (como scripts de acesso a dados ou arquivos de configuração), e (iv) um arquivo README com descrição do projeto, instruções claras de execução (incluindo dependências) e a identificação das contribuições individuais de cada membro do grupo. Submissões sem repositório acessível não serão avaliadas [Create and share with the instructor a Git-based repository (e.g., on GitHub)², so that the development can be followed throughout the process. The repository must include: (i) the final report in PDF format, (ii) all source code used in the analysis, (iii) any supporting files (such as data access scripts or configuration files), and (iv) a README file containing a project description, clear execution instructions (including dependencies), and a statement of each group member’s contributions. Submissions without an accessible repository will not be evaluated].

É permitido consultar livros, documentação, materiais didáticos e outros recursos externos, desde que todas as fontes utilizadas sejam devidamente citadas. Não é permitido utilizar ferramentas de Inteligência Artificial generativa para resolver as questões, gerar interpretações ou produzir ou modificar o código R utilizado na solução. Todos os

¹ Você pode utilizar outra plataforma baseada em Git, desde que o repositório esteja acessível sem restrições à professora.

integrantes do grupo devem ser capazes de explicar e justificar os métodos, cálculos, código e resultados apresentados. A professora poderá solicitar uma breve explicação individual ou do grupo sobre qualquer parte da solução, que poderá ser considerada na avaliação [Books, documentation, teaching materials and other external resources may be consulted, provided that all sources are properly cited. The use of generative Artificial Intelligence tools is not permitted to solve the homework questions, generate interpretations, or produce or modify the R code used in the solution. All group members must be able to explain and justify the methods, calculations, code and results presented. They may request a brief individual or group explanation of any part of the submission, which may be considered in the assessment].

Todos os integrantes do grupo são responsáveis pelo conteúdo da solução entregue. A divisão das tarefas entre os integrantes é permitida, mas todos devem compreender o trabalho como um todo, especialmente os procedimentos estatísticos, os resultados e o código apresentado [All group members are responsible for the content of the submitted solution. Tasks may be divided among group members, but everyone must understand the work as a whole, particularly the statistical procedures, results, and code presented].

A avaliação será distribuída entre as questões de acordo com a complexidade e o nível de análise esperado. A Questão 1 corresponde a 5%, a Questão 2 a 30%, a Questão 3 a 35% e a Questão 4 a 30% da nota final [Question 1 is worth 5%, Question 2 is worth 30%, Question 3 is worth 35%, and Question 4 is worth 30% of the final mark].

O relatório e os arquivos solicitados deverão ser enviados por meio do SIGAA até a data definida para o homework. Submissões com atraso serão penalizadas [The report and requested files must be submitted via SIGAA by the deadline specified for the homework. Late submissions will be penalised].

QUESTÃO 1

O conjunto de dados em anexo, `HW1_bike_sharing.csv`³, refere-se ao processo de compartilhamento de bicicletas em uma cidade dos Estados Unidos. O arquivo contém 731 observações diárias. Todos os grupos utilizarão o mesmo conjunto de dados original, mas cada grupo deverá trabalhar com uma amostra específica de 300 observações consecutivas. A seleção das observações será determinada pelos números de matrícula dos integrantes do grupo [The attached dataset, `HW1_bike_sharing.csv`³, refers to a bike-sharing system in a city in the United States. The file contains 731 daily observations. All groups will use the same original dataset, but each group will work with its own sample of 300 consecutive observations. The observations to be selected will be determined by the group student numbers of the members].

³ Os dados estão disponíveis no material do HW [The dataset is available in the HW materials].

Carregue o arquivo original no R e utilize-o para construir o conjunto de dados específico do grupo. Considere M como o maior número de matrícula entre os integrantes do grupo. Defina $r = 1 + (M \bmod 100)$. Selecione 300 observações consecutivas, iniciando na observação r . Preserve a ordem original das observações. A amostra selecionada deverá ser armazenada no objeto `data_group` e utilizada como base para todas as questões seguintes. Não altere, exclua ou reordene as observações selecionadas [Load the original file into R and use it to construct the group-specific dataset. Let M be the highest student number among the group members. Define $r = 1 + (M \bmod 100)$. Select 300 consecutive observations, starting at observation r . Preserve the original order of the observations. Store the selected sample in the object `data_group` and use it as the basis for all subsequent questions. Do not modify, delete or reorder the selected observations].

No relatório, apresente os números de matrícula dos integrantes, os valores de M e r , as datas da primeira e da última observação selecionada e o código R utilizado para construir `data_group` [In the report, provide the student numbers of all group members, the values of M and r , the dates of the first and last selected observations, and the R code used to construct `data_group`].

Os cálculos estatísticos deverão ser realizados inicialmente, de forma manual, utilizando as primeiras 10 observações do conjunto de dados do grupo. Apresente as fórmulas e os principais passos dos cálculos e, em seguida, utilize o R para verificar os resultados. Caso sejam observadas diferenças, explique sua origem, considerando diferentes métodos ou convenções de cálculo, quando pertinente. Após a verificação, aplique o mesmo código R às 300 observações do grupo e utilize esses resultados nas análises solicitadas [Statistical calculations must first be performed manually using the first 10 observations of the group's dataset. Present the formulas and the main calculation steps, and then use R to verify the results. If differences are observed, explain their origin, considering different calculation methods or conventions where relevant. After verification, apply the same R code to the 300 observations in the group dataset and use these results in the requested analyses].

QUESTÃO 2

O conjunto de dados do grupo, construído na Questão 1, contém as variáveis descritas na Tabela 1. A variável `season` representa as quatro estações do ano no Hemisfério Norte: primavera, verão, outono e inverno. A variável `weathersit` representa quatro condições meteorológicas: “Céu limpo”, “Nublado”, “Chuva fraca” e “Chuva forte”. A variável `temp` corresponde à temperatura “normalizada”, obtida pela divisão da temperatura em graus Celsius por 41. Para as análises deste trabalho, defina também a variável `total_user`, correspondente ao número total de usuários por dia: `total_user=casual+registered` [The group dataset, constructed in Question 1, contains the variables described in Table 1. The variable `season` represents the four seasons of the year in the Northern Hemisphere: spring, summer, autumn and winter. The variable `weathersit` represents four weather conditions: “Clear”, “Cloudy”, “Light Rain”, and “Heavy Rain”. The variable `temp` corres-

ponds to the “normalised” temperature, obtained by dividing the temperature in degrees Celsius by 41. For the analyses in this homework, also define the variable `total_user`, corresponding to the total number of users per day: `total_user=casual+registered`].

O primeiro objetivo é caracterizar o conjunto de dados específico do grupo, identificando suas variáveis, categorias e período observado [The first objective is to characterise the group-specific dataset by identifying its variables, categories, and observation period].

TAG	DESCRIÇÃO	DESCRIPTION
<code>instant</code>	Índice de registro	Record index
<code>dteday</code>	Data da observação	Date of observation
<code>season</code>	Estação do ano	Season
<code>weathersit</code>	Condições meteorológicas	Weather conditions
<code>temp</code>	Temperatura normalizada	Temperature normalised
<code>casual</code>	Número de usuários casuais	Number of casual users
<code>registered</code>	Número de usuários registrados	Number of registered users

Tabela 1: Variáveis do conjunto `HW1_bike_sharing`.

1. Realize as seguintes análises [Perform the following analyses]:
 - Classifique cada variável quanto ao seu tipo (categórica ou numérica) e justifique a classificação [Classify each variable according to its type (categorical or numerical) and justify the classification].
 - Identifique as categorias das variáveis categóricas [Identify the categories of the categorical variables].
 - Para cada variável numérica, identifique a unidade de medida, quando aplicável, e descreva o que ela representa [For each numerical variable, identify its unit of measurement, where applicable, and describe what it represents].
 - Verifique a existência de valores ausentes e, caso existam, quantifique-os e indique em quais variáveis ocorrem [Check for missing values and, if any are found, quantify them and indicate which variables contain them].
2. Para as variáveis numéricas relevantes, calcule as medidas de tendência central: média, mediana e, quando aplicável, moda. Explique o significado de cada medida e interprete os resultados obtidos no contexto do conjunto de dados [For the relevant numerical variables, calculate the measures of central tendency: mean, median and, where applicable, mode. Explain the meaning of each measure and interpret the results in the context of the dataset].
3. Escolha uma das variáveis numéricas relevantes e determine os quartis Q_1 , Q_2 e Q_3 e o intervalo interquartil. Justifique a escolha da variável e utilize o critério do intervalo interquartil para determinar os limites inferior e superior para a identificação

de possíveis valores atípicos. Quantifique as observações classificadas como possíveis valores atípicos e identifique suas respectivas datas. Discuta a relevância dos valores identificados para a análise do sistema [Choose one of the relevant numerical variables and determine the quartiles Q_1 , Q_2 and Q_3 and the interquartile range. Justify your choice of variable and use the interquartile range criterion to determine the lower and upper bounds for identifying potential outliers. Quantify the observations classified as potential outliers and identify their respective dates. Discuss the relevance of the identified values to the analysis of the system].

4. Para a variável numérica escolhida no item anterior, construa um histograma e um boxplot. Analise a distribuição quanto à sua forma, dispersão, assimetria e presença de possíveis valores atípicos. Relacione as características observadas nos gráficos com as medidas estatísticas calculadas anteriormente e discuta quais aspectos da distribuição são melhor evidenciados por cada tipo de gráfico [For the numerical variable selected in the previous item, construct a histogram and a boxplot. Analyse the distribution in terms of its shape, spread, skewness, and the presence of potential outliers. Relate the features observed in the plots to the statistical measures calculated previously and discuss which aspects of the distribution are better highlighted by each type of plot].
5. Com base nos quartis calculados anteriormente, utilize o primeiro quartil Q_1 como critério para classificar um dia como de “baixa utilização” do sistema. A partir desse critério, crie a variável binária `low_usage`, definida pela Equação [Based on the quartiles calculated previously, use the first quartile Q_1 as the criterion for classifying a day as having “low usage” of the system. Based on this criterion, create the binary variable `low_usage`, defined by Equation] 1.

$$\text{low_usage} = \begin{cases} 1, & \text{se } \text{total_user} < Q_1, \\ 0, & \text{caso contrário.} \end{cases} \quad (1)$$

Apresente o valor de Q_1 , determine o número e a proporção de dias classificados como de baixa utilização e explique o significado desse critério no contexto dos dados [Report the value of Q_1 , determine the number and proportion of days classified as having low usage, and explain the meaning of this criterion in the context of the data].

QUESTÃO 3

Utilize a variável `low_usage` definida na Questão 2 para investigar as características associadas aos dias de menor utilização do sistema [Use the variable `low_usage` defined in Question 2 to investigate the characteristics associated with days of lower system usage]

1. Analise a utilização do sistema em cada estação do ano. Para cada estação, calcule a média, a mediana e o desvio padrão de `total_user` e determine a proporção de dias classificados como `low_usage`. Construa um boxplot comparando as estações e discuta as principais diferenças observadas [Analyse system usage for each season of the year.

For each season, calculate the mean, median, and standard deviation of `total_user`, and determine the proportion of days classified as `low_usage`. Construct a boxplot comparing the seasons and discuss the main differences observed].

2. Analise a utilização do sistema em função das condições meteorológicas. Para cada condição, calcule a média e o desvio padrão de `total_user` e determine a proporção de dias classificados como `low_usage`. Utilize medidas estatísticas e gráficos apropriados para comparar as condições meteorológicas [Analyse system usage as a function of weather conditions. For each condition, calculate the mean and standard deviation of `total_user`, and determine the proportion of days classified as `low_usage`. Use appropriate statistical measures and plots to compare the weather conditions].
3. Investigue a relação entre a temperatura e `total_user`. Construa um gráfico de dispersão e calcule o coeficiente de correlação. Interprete a direção e a intensidade da associação e discuta possíveis limitações do coeficiente de correlação para descrever a relação observada [Investigate the relationship between temperature and `total_user`. Construct a scatter plot and calculate the correlation coefficient. Interpret the direction and strength of the association and discuss possible limitations of the correlation coefficient in describing the observed relationship].
4. Com base nas análises realizadas nesta questão, selecione duas características que parecem estar mais associadas à utilização do sistema. Justifique a escolha com base nos resultados estatísticos e/ou gráficos [Based on the analyses performed in this question, select two characteristics that appear to be most strongly associated with system usage. Justify your choice based on the statistical and/or graphical results].

QUESTÃO 4

Utilize em conjunto os resultados obtidos nas Questões 2 e 3 para aprofundar a análise do comportamento do sistema de compartilhamento de bicicletas [Use the results obtained in Questions 2 and 3 together to further analyse the behaviour of the bike-sharing system].

1. Construa a série temporal de `total_user`. Identifique períodos de maior e menor utilização e discuta os principais padrões observados [Construct a time series of `total_user`. Identify periods of higher and lower usage and discuss the main patterns observed].
2. Retome as duas características selecionadas na Questão 3. Para cada uma, escolha uma visualização e uma medida estatística adequadas para analisar sua associação com `total_user`. Apresente e interprete os resultados, comparando-os com as conclusões obtidas na Questão 3 [Revisit the two characteristics selected in Question 3. For each one, choose an appropriate visualisation and statistical measure to analyse its association with `total_user`. Present and interpret the results, comparing them with the conclusions obtained in Question 3].

3. Aprofunde a análise da relação entre temperatura e `total_user`, diferenciando visualmente os dias classificados como `low_usage` dos restantes. Discuta os principais padrões observados e avalie se a relação entre temperatura e utilização parece diferir entre os grupos [Further analyse the relationship between temperature and `total_user`, visually distinguishing days classified as `low_usage` from the others. Discuss the main patterns observed and assess whether the relationship between temperature and usage appears to differ between the groups].
4. Com base nos resultados obtidos nas três questões, escreva uma conclusão final de aproximadamente 100 - 200 palavras sintetizando os principais resultados da análise. Destaque as características que parecem estar mais associadas à utilização do sistema e sustente suas conclusões com resultados estatísticos e/ou gráficos obtidos ao longo do trabalho. Sempre que possível, apresente os valores relevantes e interprete-os no contexto do problema [Based on the results obtained in the three questions, write a final conclusion of approximately 100 - 200 words summarising the main findings of the analysis. Highlight the characteristics that appear to be most strongly associated with system usage and support your conclusions with statistical and/or graphical results obtained throughout the work. Where appropriate, report the relevant values and interpret them in the context of the problem].